



人工智能数学基础

信息论

刘昌鑫



华东理工大学

信息科学与工程学院 自动化系

能源化工过程智能制造教育部重点实验室

7-1


简介与概述






香农, 1948

“A mathematical theory of communication,”
Bell System Technical Journal. 27 (3): 379–
423, 1948.



Claude Elwood
Shannon (1916-2001)









“Advances in digital communication in the latter half of this century were guided by the lessons of **information theory** but fueled by the progress in solid state electronics.”
--IEEE Communications Magazine, Sept. 1991, A. J. Viterbi (高通创始人)

简介



克劳德·香农





• 个人简介

✓ 数学家

- ✓ Ph.D. in Mathematics from MIT. Worked at [AT&T Bell Labs](#) and RLE in [MIT](#)

✓ 电气工程师

- ✓ 硕士论文: electrical applications of Boolean algebra could construct any logical, numerical relationship

✓ 密码学家

- ✓ "A Mathematical Theory of Cryptography," 1949.

✓ 图灵的朋友

- ✓ 1943年，香农开始接触英国的顶尖数学家艾伦·图灵(Alan Turing)。图灵给香农看了他1936年的论文，内容是后世所知的通用图灵机。



香农：信息时代之父

- 百科: https://en.wikipedia.org/wiki/Claude_Shannon
- 纪录片: The bit player

豆瓣电影

搜索电影、电视剧、综艺、影人



我看

影讯&购票

选电影

电视剧

排行榜


分类

影评

2020年度榜单

2020书影音报告

香农传 The Bit Player (2018)



更新描述或海报

导演: Mark Levinson

编剧: Mark Levinson

主演: 约翰·哈顿 / 朱迪思·爱薇 / Kaliswa Brewster

类型: 纪录片 / 传记

官方网站: <https://thebitplayer.com>

制片国家/地区: 美国

语言: 英语

上映日期: 2018-06-19(美国)

IMDb: tt5015534

豆瓣评分

8.8 ★★★★★
314人评价

5星	53.9%
4星	33.1%
3星	12.6%
2星	0.4%
1星	0.0%



• A mathematical theory of communication

From *The Mathematical Theory of Communication*, ©1949 by the Board of Trustees of the University of Illinois.
Used with the permission of University of Illinois Press.

A Mathematical Theory of Communication

By C. E. SHANNON

INTRODUCTION

THE recent development of various methods of modulation such as PCM and PPM which exchange bandwidth for signal-to-noise ratio has intensified the interest in a general theory of communication. A basis for such a theory is contained in the important papers of Nyquist¹ and Hartley² on this subject. In the present paper we will extend the theory to include a number of new factors, in particular the effect of noise in the channel, and the savings possible due to the statistical structure of the original message and due to the nature of the final destination of the information.

The fundamental problem of communication is that of reproducing at one point either exactly or approximately a message selected at another point. Frequently the messages have meaning; that is they refer to or are correlated according to some system with certain physical or conceptual entities. These semantic aspects of communication are irrelevant to the engineering problem. The significant aspect is that the actual message is one selected from a set of possible messages. The system must be designed to operate for each possible selection, not just the one which will actually be chosen since this is unknown at the time of design.

If the number of messages in the set is finite then this number or any monotonic function of this number can be regarded as a measure of the information produced when one message is chosen from the set, all choices being equally likely. As was pointed out by Hartley the most natural choice is the logarithmic function. Although this definition must be generalized considerably when we consider the influence of the statistics of the message and when we have a continuous range of messages, we will in all cases use an essentially logarithmic measure.

The logarithmic measure is more convenient for various reasons:

1. It is practically more useful. Parameters of engineering importance such as time, bandwidth, number of relays, etc., tend to vary linearly with the logarithm of the number of possibilities. For example, adding one relay to a group doubles the number of possible states of the relays. It adds 1 to the base 2 logarithm of this number. Doubling the time roughly squares the number of possible messages, or doubles the logarithm, etc.
2. It is nearer to our intuitive feeling as to the proper measure. This is closely related to (1) since we intuitively measures entities by linear comparison with common standards. One feels, for example, that



• 信息论与其它领域的互动

谷歌学术(google scholar)搜索 “When Shannon Meets”

Advanced iterative channel coding schemes: When **Shannon meets** Moore
S Scholl, [S Weithoffer](#), [N Wehn](#) - 2016 9th International ..., 2016 - [ieeexplore.ieee.org](#)

Shannon meets Tesla: Wireless information and power transfer
[P Grover](#), [A Sahai](#) - 2010 IEEE international symposium on ..., 2010 - [ieeexplore.ieee.org](#)


When Bode **meets Shannon**: Control-oriented feedback communication schemes
N Elia - IEEE transactions on Automatic control, 2004 - [ieeexplore.ieee.org](#)

Capacity scaling of wireless ad hoc networks: **Shannon meets** Maxwell
SH Lee, [SY Chung](#) - IEEE Transactions on Information Theory, 2012 - [ieeexplore.ieee.org](#)

Shannon Meets Lyapunov: Connections between Information Theory and Dynamical Systems
[T Holliday](#), [P Glynn](#), [A Goldsmith](#) - Proceedings of the 44th IEEE ..., 2005 - [ieeexplore.ieee.org](#)



• 信息论与其它学科交叉





• 学术会议

IEEE International Symposium on Information Theory (ISIT)

Big Data Analytics
Coding for Communication and Storage
Coding Theory
Combinatorics and Information Theory
Communication Theory
Complexity and Computation Theory
Compressed Sensing and Sparsity
Cryptography and Security

Detection and Estimation
Distributed Storage
Emerging Applications of Information Theory
Information Theory and Statistics
Information Theory in Biology
Information Theory in Computer Science
Statistical/Machine Learning
Network Coding and Applications

Network Data Analysis
Network Information Theory
Optical Communication
Quantum Information and Coding Theory
Shannon Theory
Signal Processing
Source Coding and Data Compression
Wireless Communication and Networks



• 信息是什么？

从哲学的角度上讲，**信息**是构成物质世界的三大支柱之一，其他两个是**物质**和**能量**。

可以说我们生活在信息的海洋之中，没有信息就没有世界，当然也就没有我们人类社会。人类利用信息的历史非常悠久，而且随着人类社会的发展而发展。到了现代，信息的利用已经非常重要，以至于我们当今生活的社会被称作信息社会。可见信息的重要。

但是有史以来，人们都没有对信息下过一个确切的定义。就像对于物质和能量一样。



• 信息的定义


- ❑ 信息是信息论中最基本、最重要的概念，它是一个既抽象又复杂的概念。
- ❑ 信息的概念是在实践中产生的，以前一直被看作是消息的同义词。
- ❑ 信息的概念十分广泛，不同的定义在上百种以上。
- ❑ **数学家认为：**信息是使概率分布发生改变的东西。
- ❑ **哲学家认为：**信息是物质成分的意识成分按完全特殊的方式融合起来的产物。



历史发展

• 古代的通讯实践：原始方式

- 中国古代的“烽燧相望”
- 古罗马地中海诸城市的“悬灯为号”





• 20世纪20-60年代:

- 1928年，美国数学家哈特莱（Hartley）在《贝尔系统电话杂志》上发表了一篇题为《信息传输》的论文。他认为“**信息是选择的自由度**”。
- 美国数学家、控制论的主要奠基人维纳（Wiener）在1950年出版的《控制论与社会》一书中写到：“**信息既不是物质又不是能量，信息就是信息**”。这句话起初受到批评和嘲笑。但正是这句话揭示了信息的特质：即信息是独立于物质和能量之外存在于客观世界的**第三要素**。
- 1948年，另一位美国数学家香农在《贝尔系统电话杂志》上发表了题为《通讯的数学理论》的长篇论文。他创立了信息论，他认为“**信息是事物运动状态或存在方式的不确定的描述**”。



• 20世纪70年代以后:

- 随着数学计算机的广泛应用和社会信息化的迅速发展，信息论正逐渐突破香农狭义信息论的范围。
- 信息论迅速渗透到各个不同学科领域，但还不够完善。为了适应科学技术发展的需要，迎接信息化社会的到来，一门新的科学正在迅速兴起，这就是广义信息论，或者叫做信息科学。
- 信息科学是由信息论、控制论、计算机、人工智能和系统论等相互渗透、相互结合而形成的一门新兴综合性学科。



- 信息虽无确切定义，但是却具有两个明显的特征：广泛性与抽象性。

➤ 广泛性

- 客观世界充满着信息
- 人类离不开信息
- 知识、书本是有用信息的积累

➤ 抽象性

- 三大要素是：物质、能量与信息。三要素中物质是基础，是实体。能量是物质运动的形式， $E=mc^2$ ，物质可转换成能量，而能量又是改造客观世界的主要动力。



信息特征

- **信息：**它依附于物质和能量，但又不同于物质和能量。没有信息就不能更好地利用物质和能量，人类利用信息和知识改造物质，创造新物质，提高能量利用效率，发现新能量形式。信息也是客观存在的，它是人类认识、改造客观世界的主要动力，是人类认识客观世界的更高层次。
- 就狭义而言，在通信中对信息的表达分为三个层次：信号、消息、信息。




信息特征

- **信号：**是信息的物理表达层，是三个层次中最具体的层次。它是一个物理量，是一个载荷信息的实体，可测量、可描述、可显示。如电信号、光信号等。
- **消息：**(或称为符号)是信息的数学表达层，它虽不是一个物理量，但是可以定量地加以描述，它是具体物理信号的进一步数学抽象。
- **信息：**信息是指各个事物运动的状态及状态变化的方式。人们从来自对周围世界的观察得到的数据中获得信息。信息是抽象的意识或知识，它是看不见、摸不到的。人脑的思维活动产生的一种想法，当它仍储存在脑子中的时候就是一种信息。信息是信号与消息的更高表达层次。三个层次中，信号最具体，信息最抽象。它们三者之间的关系是哲学上的内涵与外延的关系。




通信系统基本模型



- 信源
- 编码器（发送设备）
- 信道
- 译码器（接收设备）
- 信宿




通信系统基本模型



- **信源：**信源是信息的发源地。
 - 信源消息有多种形式，可以是离散的或连续的，也可以是时间序列，它们分别可用离散型随机变量、连续型随机变量及随机过程等数学模型表示
- **信宿：**信宿即信息传输的目的地。




通信系统基本模型



- **编码器：**编码是对消息符号进行编码处理的过程。编码包括信源编码、保密编码、信道编码等。
 - 信源编码：对信源输出的消息进行适当的变换和处理，以尽可能提高信息传输的效率；
 - 信道编码：为了提高信息传输的可靠性而对信息进行的变换和处理。
- **译码器：**译码是把信道输出的编码信号进行反变换，以尽可能准确地恢复原始的信源符号。
 - 与编码器相对应的译码器也有信源译码器和信道译码器等。



通信系统基本模型



- **信道：**信道是信息的传递媒介。实际的信道有明线、电缆、波导、光纤、无线电波传播空间等。
 - 信息的传输不可避免地会引入噪声和干扰，为了分析方便，通常把系统所有其他部分的干扰和噪声都等效地折合成信道干扰，这些干扰被看成是由一个噪声源产生的，并叠加于所传输的信号上。这样，信道的输出是已经叠加了干扰的信号。
 - 由于干扰和噪声均具有随机性，所以信道的特性同样可以用概率模型来描述，而噪声源的统计特性又是划分信道类型的主要依据。



通信的基本问题

- 香农指出，通信的基本问题是在一点精确地或近似地恢复另一点所选择的信息。从这个基本问题出发，对通信系统指定了3项性能指标：**传输的有效性**、**传输的可靠性**、**传输的安全性**。
 - 有效性：信源代码应尽量短；
信息传输应尽量快，即高的传信率；
信息传送应该尽量节省资源，即高的频谱利用率。
 - 可靠性：是指传输差错要尽量少，对数字传输就是要求低的误码率。
 - 安全性：是指传输的信息不能泄露给未授权人。
- 3项性能指标所对应的3项基本技术是：**数据压缩**、**数据纠错**和**数据加密**。



信息论的研究

- **信息论：专门研究信息的有效处理和可靠传输的一般规律的科学。**

■ 狭义信息论，即通信的数学理论，主要研究狭义信息的度量方法，研究各种信源、信道的描述和信源、信道的编码定理。

■ 实用信息论，研究信息传输和处理问题，也就是狭义信息论方法在调制解调、编码译码以及检测理论等领域的应用。

■ 广义信息论，包括信息论在自然和社会中的新的应用，如模式识别、机器翻译、自学习自组织系统、心理学、生物学、经济学、社会学等一切与信息问题有关的领域。



信息的分类

① 按照信息的性质

语法

语义

语用

② 按照观察的过程

实在

先验

实得

③ 按照信息的地位

客观

主观



信息的分类

④ 按照信息的作用

有用

无用

干扰

⑤ 按照信息的逻辑意义

真实

虚假

不定

⑥ 按照信息的传递方向

前馈

主馈



信息的分类

⑦ 按照信息的生成领域

宇宙

自然

社会

思维

⑧ 按照信息的应用部门

工业

农业

军事

政治

科技

文化

经济

市场

管理

⑨ 按照信息的来源

语音

图像

文字

数据

计算



信息的分类

⑩ 按照信息载体的性质

语音

图像

文字

电磁

光学

生物

⑪ 按照携带信息的信号的性质

连续

半连续

离散



信息论的研究

- 信源与熵
- 无失真信源编码
- 信道容量与信息的可靠传输
- 信息率失真理论（数据压缩的理论基础）



• 信息论在信息技术领域中的应用

- 20 世纪 70、80 年代的编码理论在快速通信技术中得到了大量应用. 当时的通信技术正在从低速向高速过渡, 通信手段正向微波和卫星等方向发展. 因此, 误差干扰问题就突现出来. 利用纠错码可大大降低通信中的差错率.
- 另外, 卷积码理论当时也有重要的发展, 如卷积码的Viterbi 译码算法改造了新一代卫星的通信技术, 成为当时信息论和编码理论在工程技术应用中的一个光辉典范。

• 在调制解调码技术中的应用

- 20 世纪 80、90 年代调制解调码理论和数据压缩理论在多媒体技术领域中的应用是信息论和编码理论应用的两项重要成果.
- 调制解调码的出现, 从根本上改变了数据通信的状况, 使调制解调码的通信速度从原来的 1200bit/s 逐步提高到 30000bit/s. 数据传输速度提高了近 30 倍, 从而使现有的网络通信成为实用性的技术。




- **数据压缩理论和技术**
 - 数据压缩理论分为无失真压缩和有失真压缩两大部分. 它们有各自的理论基础和应用范围. 无失真压缩理论和技术与数据存储密切相关, 目前在计算机数据和文件的存储中得到了广泛应用, 它又是有失真压缩理论和技术的基础。
- **编码技术在其他领域中的应用**
 - 信息论和编码理论除了在电子和计算机以及通信工程中有大量的应用之外, 值得注意的应用问题还有很多, 如汉字信息处理问题、条码和磁码技术等。



数据压缩

各种数据压缩工具的局限是? (*.rar, *.zip, *.7z)



如何设计视频格式标准?





存储

- 冗余与效率




(Lena Forsen)

Can we recover it?



How to process and store data.




Big data: Distributed computation, distributed storage



安全

I have a secret to share... However ...



Big data, machine learning and security: All you need is information theory



Shannon and his **electromechanical** mouse *Theseus* (named after **Theseus** from Greek mythology) which he tried to have solve the maze in one of the first experiments in **artificial intelligence**

“Reinforcement Learning”



Deep Learning (AI)中的信息论应用

- ❑ Popular **cross-entropy** loss function
- ❑ Building decision trees on basis of maximum **information gain**
- ❑ **Viterbi algorithm** widely used in NLP and Speech
- ❑ Concept of **encoder-decoder** popularly used in Machine Translation RNNs and various other type of models



7-2

信息的度量





- 先验概率及概率空间的形式

- 符号 x_i 的先验概率

一个离散信源发出的各个符号消息的集合为

$$X = \{x_1, x_2, \dots, x_n\}, \text{ 它们的概率分别为}$$
$$P = \{p(x_1), p(x_2), \dots, p(x_n)\}, \quad p(x_i)$$

为符号 x_i 的先验概率。通常把它们写

到一起，称为概率空间：



- 先验概率及概率空间的形式

- 符号 x_i 的先验概率

$$\begin{bmatrix} X \\ P \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \\ p(x_1) & p(x_2) & \cdots & p(x_n) \end{bmatrix}$$

显然有 $p(x_i) \geq 0, \sum_{i=1}^n p(x_i) = 1$



- 信息量 $I(x)$ 与概率 $p(x)$ 之间的关系
 - 单调递减;
 - 小概率事件发生, 信息量大
 - 概率为1的事件: 无信息量
 - 可加性

例子:

- (1) 马斯克的生日处在一年之中的特定一天;
- (2) 马斯克的生日处在上半年;
- (3) 马斯克的生日是某月的28日。



- **定义：对某事件不确定性的度量**

- 一个随机事件的自信息量定义为其出现概率对数的负值。即：

$$I(x_i) = -\log p(x_i)$$

说明：

- a. 因为概率 $p(x_i)$ 越小， x_i 的出现就越难，一旦出现，所获得的信息量也就较大。由于 x_i 是随机出现的，它是 X 的一个样值，所以是一个随机量。
而 $I(x_i)$ 是 x_i 的函数，它必须也是一个随机量。



b. 自信息量的单位的确定

- 在信息论中常用的对数底是**2**，信息量的单位为比特（**bit**）；
- 若取自然对数，则信息量的单位为奈特（**nat**）；
- 若以**10**为对数底，则信息量的单位为笛特（**det**）。

这三个信息量单位之间的转换关系如下：

$$1 \text{ nat} = \log_2 e \approx 1.433 \text{ bit},$$

$$1 \text{ det} = \log_2 10 \approx 3.322 \text{ bit}$$



• 例子

- i. 一个以等概率出现的二进制码元（**0**，**1**）所包含的自信息量为：

$$\mathbf{I(0) = I(1) = -\log_2(1/2) = \log_2 2 = 1 \text{ bit}}$$

- ii. 若是一个m位的二进制数，因为该数的每一位可从0, 1两个数字中任取一个，因此有 2^m 个等概率的可能组合。所以 $I = -\log_2(1/2^m) = m \text{ bit}$ ，就是需要m比特的信息来指明这样的二进制数。



不确定度

- 定义：随机事件的不确定度在数量上等于它的自信息量。

说明：

- a. 两者的单位相同，但含义却不相同。
- b. 具有某种概率分布的随机事件不管发生与否，都存在不确定度，不确定度表征了该事件的特性，而自信息量是在该事件发生后给予观察者的信息量。
- c. 一个出现概率接近于**1**的随机事件，发生的可能性很大，所以它包含的不确定度就很小；反之，一个出现概率很小的随机事件，很难猜测在某个时刻它能否发生，所以它包含的不确定度就很大；若是确定性事件，出现概率为**1**，则它包含的不确定度为**0**。



- 两个消息 x_i, y_j 同时出现的联合自信息量

$$I(x_i y_j) = -\log p(x_i y_j)$$

■ 注意:

- a. 当 x_i, y_j 相互独立时, 有 $P(x_i y_j) = P(x_i)P(y_j)$, 那么就有 $I(x_i y_j) = I(x_i) + I(y_j)$ 。
- b. $x_i y_j$ 所包含的不确定度在数值上也等于它们的自信息量。



条件自信息量

定义：在事件 $\mathbf{y}_j$ 出现的条件下，随机事件 $\mathbf{x}_i$ 发生的条件概率为 $p(x_i|y_j)$ ，则它的条件自信息量定义为条件概率对数的负值：


$$I(x_i|y_j) = -\log p(x_i|y_j)$$

注意：

在给定 $\mathbf{y}_j$ 条件下，随机事件 $\mathbf{x}_i$ 所包含的不确定度在数值上与条件自信息量相同，但两者含义不同。



• 先验概率与后验概率




1. 什么叫信源X的先验概率 $p(x_i)$?

由于信宿事先不知道信源在某一时刻发出的是哪一个符号, 所以每个符号消息是一个随机事件。信源发出符号通过有干扰的信道传递给信宿。通常信宿可以预先知道信息X发出的各个符号消息的集合, 以及它们的概率分布, 即预知信源X的先验概率 $p(x_i)$ 。



- 先验概率与后验概率




2. 什么叫后验概率？

当信宿收到一个符号消息 y_j 后，信宿可以计算信源各消息的条件概率 $p(x_i/y_j)$, $i=1,2,\dots,N$, 这种条件概率称为后验概率。



• 互信息量



互信息量为观察事件传输前后，这两者之差就是通信过程中所获得的信息量，即后验概率与先验概率比值的对数：

$$I(x_i; y_j) = I(x_i) - I(x_i | y_j)$$

$$= -\log p(x_i) - (-\log p(x_i | y_j)) = \log \frac{p(x_i | y_j)}{p(x_i)}$$



• 定义

条件互信息量是三维 XYX 联合集中，在给定 z_k 条件下， x_i 与 y_j 之间的互信息量，定义为：



$$I(x_i; y_j | z_k) = \log \frac{p(x_i | y_j z_k)}{p(x_i | z_k)}$$

$$I(x_i; y_j z_k) = I(x_i; z_k) + I(x_i; y_j | z_k)$$

一个联合事件 $y_j z_k$ 出现后所提供的有关 x_i 的信息量 $I(x_i; y_j z_k)$ 等于 z_k 事件出现后提供的有关 x_i 的信息量 $I(x_i; z_k)$ ，加上在给定 z_k 条件下再出现 y_j 事件后所提供的有关 x_i 的信息量 $I(x_i; y_j / z_k)$ 。

7-3

信息熵






热力学熵



熵 (Entropy) 的科学含义



鲁道夫·克劳修斯 (Rudolf Clausius)

1850-1865年之间正式提出热力学第二定律和热力学熵的概念。

熵在经典力学上的含义更容易理解，即世界上没有永动机，最终会走向平衡静止，即熵死。




高度有序

熵增



无序度增加

热力学第二定律: 不可逆性



Ludwig Eduard Boltzmann
1844-1906
Vienna, Austrian Empire

- 分析单个原子的运动非常困难
- 从系统整体来研究
- 统计力学代替牛顿力学

• 熵：反映系统混乱程度的量




熵 (Entropy)

熵

熵其实并不神秘，和长度一样，
是用来量东西的。它用来衡量
无序，就是一个东西有多乱...



比如，同样是细胞...



健康有活力的结构
有序



破败而衰老的结构
无序

而且，科学家发现，一个东西放在那，甭管它自己怎么运动，
只会变得越来越混乱、无序，也就是说，熵只会越来越大。

这就叫熵增定律。







熵的由来

'My greatest concern was what to call it. I thought of calling it 'information,' but the word was overly used, so I decided to call it 'uncertainty.' When I discussed it with John von Neumann, he had a better idea. Von Neumann told me, 'You should call it entropy, for two reasons. In the first place your uncertainty function has been used in statistical mechanics under that name, so it already has a name. In the second place, and **more important, no one really knows what entropy really is, so in a debate you will always have the advantage.**'


--Shannon explained the name 'entropy'



Thermodynamics



Quantum information



Blackhole

Information is not Matter or Energy. Hard to understand its meaning intuitively.



• 信源分类

➤ 根据样本空间取值分布不同，信源可分为以下两类：

1. 连续信源

连续信源是指发出在时间和幅度上都是连续分布的连续消息（模拟消息）的信源，如语言、图像、图形等都是连续消息。

2. 离散信源

离散信源是指发出在时间和幅度上都是离散分布的离散消息的信源，如文字、数字、数据等符号都是离散消息。



• 信源分类

➤ 根据其统计特性，信源又分为以下两类：

1. 无记忆信源

无记忆信源是指不同时刻的消息的取值相互独立；或者说，消息的概率分布与它发生的时刻毫无关联。

2. 有记忆信源

有记忆信源是指某时刻消息的取值与前面若干时刻消息的取值有关联，如中文句子中前后文字的出现是有依赖性的；为了描述这种关联性，有记忆信源的数学模型通常采用联合概况空间来描述。



熵的定义

定义： 离散信源熵 $H(X)$ 为信源中各个符号不确定度的数学期望，即：

$$H(X) = \sum_i p(x_i) I(x_i) = - \sum_i p(x_i) \log p(x_i)$$

- 单位为：比特/符号 或 比特/符号序列

信息熵 $H(X)$ 表示信源输出后，每个信息（或符号）所提供的平均信息量
平均不确定度/平均信息量/平均自信息量)



熵的性质

- 因为 $\mathbf{X}$ 中各符号 $\mathbf{x}_i$ 的不确定度 $\mathbf{I}(\mathbf{x}_i)$ 为非负值， $\mathbf{p}(\mathbf{x}_i)$ 也是非负值，且 $0 \leq \mathbf{p}(\mathbf{x}_i) \leq 1$ ，故信源的平均不确定度 $\mathbf{H}(\mathbf{X})$ 也是非负量。
- 某一信源，不管它是否输出符号，只要这些符号具有某些概率特性，必有信源的熵值；这熵值是在总体平均上才有意义，因而是一个确定值。
- 当某一符号 x_i 的概率 p_i 为零时， $p_i \log p_i$ 在熵公式中无意义，为此规定这时的 $p_i \log p_i$ 也为零。当信源 $\mathbf{X}$ 中只含一个符号 x 时，必定有 $p(x)=1$ ，此时信源熵 $\mathbf{H}(\mathbf{X})$ 为零。



例：天气预报，有两个信源

$$\begin{bmatrix} X_1 \\ p(x) \end{bmatrix} = \begin{bmatrix} a_1, & a_2 \\ 1/4, & 3/4 \end{bmatrix} \quad \begin{bmatrix} X_2 \\ p(x) \end{bmatrix} = \begin{bmatrix} a_1, & a_2 \\ 1/2, & 1/2 \end{bmatrix}$$

则：

$$H(X_1) = \frac{1}{4} \log 4 + \frac{3}{4} \log \frac{4}{3} = 0.809$$

$$H(X_2) = \frac{1}{2} \log 2 + \frac{1}{2} \log 2 = 1$$

说明第二个信源的平均不确定性更大一些



- 例：电视屏上约有 $500 \times 600 = 3 \times 10^5$ 个格点，按每点有 **10** 个不同的灰度等级考虑，则共能组成 $n=10^{3 \times 10^5}$ 个不同的画面。按等概率 $1/10^{3 \times 10^5}$ 计算，平均每个画面可提供的信息量为

$$H(X) = - \sum_{i=1}^n p(x_i) \log_2 p(x_i) = -\log_2 10^{-3 \times 10^5}$$

$$= 3 \times 10^5 \times 3.32 \text{ 比特/画面}$$



- 有一篇千字文章，假定每字可从万字表中任选，则共有不同的千字文

$$N = 10000^{1000} = 10^{4000} \text{ 篇}$$

仍按等概率 $1/10000^{1000}$ 计算，平均每篇千字文可提供的信息量为

$$\begin{aligned} H(X) &= \log_2 N \\ &= 4 \times 10^3 \times 3.32 \\ &\approx 1.3 \times 10^4 \text{ 比特 / 千字文} \end{aligned}$$

比较：

- “一个电视画面” 平均提供的信息量远远超过 “一篇千字文” 提供的信息量。



- 该信源 X 输出符号只有两个，设为0和1。输出符号发生的概率分别为 p 和 q ， $p+q=1$ 。即信源的概率空间为

$$\begin{pmatrix} X \\ P \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ p & q \end{pmatrix}$$

则二元信源熵为

$$\begin{aligned} H(X) &= -p\log p - q\log q \\ &= -p\log p - (1-p)\log(1-p) \\ &= H(p) \end{aligned}$$




FIGURE 2.1. $H(p)$ vs. p .

- 信源信息熵 $H(X)$ 是概率 p 的函数，通常用 $H(p)$ 表示。 p 取值于 $[0, 1]$ 区间。 $H(p)$ 函数曲线如图所示。从图中看出，如果二元信源的输出符号是确定的，即 $p=1$ 或 $q=1$ ，则该信源不提供任何信息。反之，当二元信源符号0和1以等概率发生时，信源熵达到极大值，等于1比特信息量。



定义：在给定 $\mathbf{y}_j$ 条件下， $\mathbf{x}_i$ 的条件自信息量为 $\mathbf{I}(\mathbf{x}_i | \mathbf{y}_j)$ ， $\mathbf{X}$ 集合的条件熵 $\mathbf{H}(\mathbf{X} | \mathbf{y}_j)$ 为

$$\mathbf{H}(\mathbf{X} | \mathbf{y}_j) = \sum_i p(x_i | y_j) I(x_i | y_j)$$

在给定 $\mathbf{Y}$ （即各个 $\mathbf{y}_j$ ）条件下， $\mathbf{X}$ 集合的条件熵 $\mathbf{H}(\mathbf{X} / \mathbf{Y})$ 定义为

$$\begin{aligned} \mathbf{H}(\mathbf{X} | \mathbf{Y}) &= \sum_j p(y_j) H(X | y_j) = \sum_{i,j} p(y_j) p(x_i | y_j) I(x_i | y_j) \\ &= \sum_{i,j} p(x_i y_j) I(x_i | y_j) \end{aligned}$$



定义：联合熵是联合符号集合 XY 上的每个元素对 $x_i y_j$ 的自信息量的概率加权统计平均值。定义为：

$$H(XY) = \sum_{i,j} p(x_i y_j) I(x_i y_j) = - \sum_{i,j} p(x_i y_j) \log p(x_i y_j)$$

说明：联合熵 $H(XY)$ 表示 X 和 Y 同时发生的不确定度。

联合熵 $H(XY)$ 与熵 $H(X)$ 及条件熵 $H(X|Y)$ 之间存在下列关系

1) $H(XY) = H(X) + H(Y|X)$

2) $H(XY) = H(Y) + H(X|Y)$



相对熵：两个概率分布的“距离”

取值集合为 $\mathcal{X}$ 的两个随机变量的概率密度函数 $p(x)$ 和 $q(x)$ 之间的相对熵，或称 **Kullback–Leibler (KL) 距离**，定义为

$$\begin{aligned} D(p||q) &= \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)} \\ &= E_p \left[\log \frac{p(X)}{q(X)} \right] \end{aligned}$$

应用：当两个随机分布相同时，它们的相对熵为零；当两个随机分布的差别增大时，它们的相对熵也会增大。所以，相对熵可以用于比较文本的相似度，即先统计词的频率，然后计算相对熵。



平均互信息量

两个随机变量 X 和 Y 有联合概率密度分布 $p(x, y)$ 及边际密度分布 $p(x)$ 和 $p(y)$ 。它们的互信息 $I(X; Y)$ 是联合分布 $p(x, y)$ 和边际分布乘积 $p(x)p(y)$ 的相对熵：

$$\begin{aligned} I(X; Y) &= \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)} \\ &= D(p(x, y) || p(x)p(y)) \\ &= E_{p(x, y)} \left[\log \frac{p(X, Y)}{p(X)p(Y)} \right] \end{aligned}$$

- $I(X; Y) = I(Y; X)$
- $I(X; X) = H(X)$
- X 和 Y 相互独立：

$$I(X; Y) = 0$$



说明:


- a. 在通信系统中，若发端的符号是 $\mathbf{X}$ ，而收端的符号是 $\mathbf{Y}$ ， $\mathbf{I}(\mathbf{X}; \mathbf{Y})$ 就是在接收端收到 $\mathbf{Y}$ 后所能获得的关于 $\mathbf{X}$ 的信息。
- b. 若干扰很大， $\mathbf{Y}$ 基本上与 $\mathbf{X}$ 无关，或说 $\mathbf{X}$ 与 $\mathbf{Y}$ 相互独立，那时就收不到任何关于 $\mathbf{X}$ 的信息。
- c. 若没有干扰， $\mathbf{Y}$ 是 $\mathbf{X}$ 的确知一一对应函数，那就能完全收到 $\mathbf{X}$ 的信息 $\mathbf{H}(\mathbf{X})$ 。

性质:

- 1) $\mathbf{I}(\mathbf{X}; \mathbf{Y}) = \mathbf{H}(\mathbf{X}) - \mathbf{H}(\mathbf{X}|\mathbf{Y})$
- 2) $\mathbf{I}(\mathbf{Y}; \mathbf{X}) = \mathbf{H}(\mathbf{Y}) - \mathbf{H}(\mathbf{Y}|\mathbf{X})$
 $= \mathbf{I}(\mathbf{X}; \mathbf{Y})$



- Venn图: $H(X, Y), H(X), H(Y), I(X; Y)$





$$\begin{aligned} I(X; Y) &= H(X) - H(X|Y) \\ I(X; Y) &= H(Y) - H(Y|X) \\ I(X; Y) &= H(X) + H(Y) - H(X, Y) \\ I(X; Y) &= I(Y; X) \\ I(X; X) &= H(X) \end{aligned}$$

说明：通信前，随机变量X和随机变量Y可视为统计独立，其先验不确定性为 $H(X)+H(Y)$ ；通信后，整个系统的后验不确定性为 $H(X, Y)$ ，二者之差就是通信过程中不确定性减少的量，也就是通信过程中获得的平均互信息量。




7-4

信道与编码






噪声的世界





信息传输中的噪声

- 通过 Email/QQ/微信发信息时，可能由于各种网络环境原因遇到发送失败的情况





信道的定义

- **消息(message)**: 离散随机变量 M , 取值集合 $\mathcal{M}$
 - 输入消息 X , 取值集合 $\mathcal{X}$
 - 输出消息 Y , 取值集合 $\mathcal{Y}$

信道将 X 变成 Y , 该变换可以建模为随机变量 X 和 Y 之间的概率转移矩阵:

$$p(Y|X)$$

- 信息长度过大时, 需进行多次通讯传输:

$$M \rightarrow X_1, \dots, X_n$$

即信道被使用 n 次, 该情形用随机过程 $\{X_i\}$ 来表示。




信道的分类

- 根据输入和输出信道的特点
 - 离散信道（数字信道）：时间离散、取值离散
 - 波形信道（模拟信道）：时间连续、取值连续
 - 半连续信道：输入和输出序列一个离散一个连续
 - 连续信道：时间离散、取值连续
- 根据统计特性
 - 无记忆信道：输出只与当前输入有关
 - 有记忆信道：不仅与当前输入有关，还与以前的输入有关
- 根据传输媒质
 - 无线信道
 - 有线信道



离散无记忆信道



- 需求: $\hat{W} \rightarrow W$


- 离散信道: 一个系统, 包含一个输入集合 $\mathcal{X}$, 一个输出集合 $\mathcal{Y}$, 和一个概率转移矩阵 $p(y|x)$
- 无记忆性: 输出的概率分布只依赖于当次输入, 与之前的信道输入和输出无关 (每次都可视作一个新信道)

➤ 概率转移矩阵是信道的物理性质, 和编码无关

➤ 三元组: $(\mathcal{X}, p(y|x), \mathcal{Y})$




无干扰信道



- 二元输入，输出复现输入，确定的对应关系
- 没有噪声
- 信道概率转移矩阵：单位矩阵




二元对称信道



- 特征：如果通信发生错误，发送0会收到1，发送1会收到0。
- 具有通信错误的信道的最简单模型之一




二元擦除信道



- 类似于二元对称信道；但是不是发生错误，而是信息丢失。在该信道中， α 比例的传输字节会被丢失。
- 接收方是知道哪些字节丢失的。
- 可视为有两个输入，三个输出。



二元Z信道



- 发送0收到还是0，发送1有一定概率收到0.
- 概率转移矩阵:

$$p(Y|X) = \begin{bmatrix} 1 & 0 \\ \delta & 1 - \delta \end{bmatrix}, x, y \in \{0, 1\}$$



信道容量定义

定义一个离散无记忆信道的**信道容量 (channel capacity)** 为

$$C = \max_{p(x)} I(X; Y),$$

其中max的取值范围为输入变量的所有可能的概率分布。

性质

- $C \geq 0$, 由 $I(X; Y) \geq 0$
- $C \leq \log |\mathcal{X}|$, 由 $C = \max I(X; Y) \leq \max H(X) = \log |\mathcal{X}|$
- $C \leq \log |\mathcal{Y}|$
- $I(X; Y)$ 是 $p(x)$ 的连续函数
- $I(X; Y)$ 是 $p(x)$ 的凹函数 (concave)
 - 因为 $I(X; Y)$ 闭凸集上的凹函数, 局部最大值即全局最大
 - $\sup I(X; Y) = \max I(X; Y)$

“ $C = I(X; Y)$ ” 信息时代最重要的公式




信道容量性质

计算 C 的一般策略:

- $I(X; Y) = H(Y) - H(Y|X)$
 - 根据概率转移矩阵估计 $H(Y|X) = \sum_x H(Y|X = x)p(x)$
 - 估计 $H(Y)$
 - 在某些特殊场合, $I(X; Y) = H(X) - H(X|Y)$
 - 根据问题中的相关条件, 估计 $H(X|Y)$
 - 估计 $H(X)$
- 除了一些特殊的 $p(y|x)$, 一般而言, 没有信道容量一般性显式表达式, 需要根据具体问题具体分析



二元无干扰信道



$$C = \max I(X; Y) = \max I(X; X) = \max H(X) \leq 1,$$

最大值在 $p(x) = \left(\frac{1}{2}, \frac{1}{2}\right)$ 时取到。



编码的建模

- 一个编码包括消息集合 $\mathcal{M}$ ，一个编码器和一个解码器。
- 编码器通过 n 次传输发送一个字符 $w \in \mathcal{M}$
 - 编码器: $f(w): \mathcal{M} \rightarrow \mathcal{X}^n$ (1-1)
 - f 产生了 $\mathcal{X}^n$ 的一个分布 $\xrightarrow{\text{DMC}}$ $\mathcal{X}$ 上的一个分布
 - 编码规则 $f(w) = x^n \in \mathcal{X}^n$ 生成了一个码本codebook
 - 发送和接收方共享码本
 - 当 f 确定时，等于也确定了随机变量 X^n
- 解码器接收 $y^n \sim p(y^n|x^n) = \prod p(y_n|x_n)$
 - 解码器需要根据 y^n 猜测可能的 x^n
 - 根据码本, $f^{-1}(x^n) = w$, 解码器可以获得 $\hat{w}$
 - 如果 $\hat{w} \neq w$, 则出错

$$f: \mathcal{M} \rightarrow \mathcal{X}^n \text{ and } g: \mathcal{Y}^n \rightarrow \mathcal{M}$$
$$W \rightarrow X^n \rightarrow Y^n \rightarrow \hat{W}$$



网络威胁

- 非授权访问
- 信息丢失或泄露
- 破坏数据完整性
- 干扰服务系统



网络威胁

- 窃听（秘密泄露）：机密性
- 篡改（信息被修改）：完整性
- 伪装（伪装成真正的发送者）：认证
- 否认（不承认自己发送的信息）：不可否认性



- 对称密码(**symmetric cryptography**)

加密和解密使用同一密匙。

- 公钥密码(**public-key cryptography**)

加密和解密使用不同密钥的方式。

- 单向散列函数(**one-way hash function**)

计算散列值，保证的不是机密性，而是完整性。

- 消息认证码(**message authentication code**)

确认消息是否被篡改，而且能够确认消息是否来自所期待的通信对象。

- 数字签名(**digital signature**)

为了防止通信方的否认

- 伪随机数生成器(**pseudo random number generator, PRNG**)

模拟产生随机数的算法