



• 一致连续性 (Uniform Continuity) 的定义

给定函数 $f: I = [a, b] \mapsto \mathbb{R}$ 称为一致连续的，如果对于任意 $\varepsilon > 0$ 存在 $\delta > 0$ ，对于 $\forall x_1, x_2 \in [a, b]$ 只要满足 $|x_1 - x_2| < \delta$ ，就有下式成立

$$|f(x_1) - f(x_2)| \leq \varepsilon$$

$f(x_1)$ 和 $f(x_2)$ 之间的距离并不依赖于 x_1 和 x_2 的位置，即 δ 不依赖于定义域上的点的位置，只与 ε 有关

• 一致连续性的几何意义

- 一致连续保证当函数 $f(x)$ 在从点 x_1 到点 x_2 ，如果自变量的变化非常小且一致小于 δ ，那么 $f(x)$ 的变化也是非常小，且一致小于 ε
- 一致连续性保证的是函数图像更加光滑，在整个区间上避免比较突兀的走势变化




一致连续性的几何意义

- 连续是指函数图像在任意点处都可用一个矩形框框住，而一致连续不仅要求连续，而且要求矩形框是大小统一的

范例

- $f(x) = 1/x$ 在 $[0, +\infty)$ 不是一致连续函数，因为在区间 $[0, 1]$ 这里长*宽 = $2\varepsilon * 2\delta$
- $f(x) = \sqrt{x}$ 在 $[0, +\infty)$ 是一致连续函数，
 $\varepsilon = 0.5, \delta = 0.2$
- 注意： $f(x) = 1/x$ 在 $[1, +\infty)$ 上是一致连续函数





一致连续性的性质

- 一个函数在某度量空间上一致连续，则其在此度量空间上必然连续，但反之未必成立，即一致连续 $\Rightarrow$ 连续
- 函数的一致连续是针对定义域来说的，函数 $f(x) = 1/x$ 在 $(0, +\infty)$ 上不是一致连续

$\because$ 存在 $\varepsilon = 1$ 对任意 $\delta > 0$ 使得有 $x_1 = \min\{1/2, \delta\}$, $x_2 = x_1/2$, 满

足 $|x_2 - x_1| = \frac{x_1}{2} < \delta$, 但是 $|f(x_1) - f(x_2)| = \frac{1}{x_1} \geq 2 > 1 = \varepsilon$

➤ 但是 $f(x) = 1/x$ 在 $[1, 2]$ 上却是一致连续

- 假设函数 f, g 在区间 $I \subseteq \mathbb{R}$ 上都是一致连续的
 - 对于任意常数 $\alpha, \beta \in \mathbb{R}$, $\alpha f + \beta g$ 在区间 I 上是一致连续的
 - f, g 在区间 I 上有界 $\Rightarrow f(x)g(x)$ 在区间 I 上是一致连续的
 - 范例: $f(x) = x$, $g(x) = \sin x$, 在区间 $I = (-\infty, +\infty)$ 上 $f(x)$, $g(x)$ 为一一致连续, 但 $f(x)g(x) = x \sin x$ 在区间 I 上非一致连续的



函数的连续性

一致连续性的性质

- 假设函数 f, g 在区间 $I \subseteq \mathbb{R}$ 上都是一致连续的
 - $f(x)$ 在 I 上有界, 且存在 $\varepsilon_0 > 0$ 满足 $g(x) > \varepsilon_0$ 对任意 $x \in I$ 都成立
 - ➔ $f(x)/g(x)$ 在区间 I 上是一致连续的
- 函数 f 在闭区间 $[a, b]$ 上连续 $\longleftrightarrow$ f 在闭区间 $[a, b]$ 上一致连续
- 函数 f 在开区间 (a, b) 上连续 $\longleftrightarrow$ f 在开区间 (a, b) 上一致连续
- 函数 f 在开区间 (a, b) 上连续 $\not\longleftrightarrow$ f 在开区间 (a, b) 上一致连续
 - $f(x) = 1/x$ 在 $(0, 1)$ 上连续, 但不是一致连续
- 给定连续函数 $f \in \mathcal{C}((a, b))$ $\longrightarrow$ 函数 f 在 (a, b) 上一致连续 **当且**
 - 仅当** 极限 $\lim_{x \rightarrow a^+} f(x)$ 和 $\lim_{x \rightarrow b^-} f(x)$ 都存在并有限
- 连续有界函数不一定一致连续



一致连续性的性质

■ 连续有界函数不一定一致连续

- 例如, $f(x) = \sin(x^2)$ 在 $[0, +\infty)$ 上连续且有界, 存在 $\varepsilon_0 = 1/2$, 对任意 $\delta > 0$ 使得有 $n_0 \in \mathbb{N}$ 满足 $\frac{1}{\sqrt{n_0}} < \delta$, 从而存在

$$x_1 = \sqrt{2n_0\pi}, \quad x_2 = \sqrt{2n_0\pi + \frac{\pi}{2}}$$

满足

$$0 < x_2 - x_1 = \frac{\pi}{2}(x_2 + x_1)^{-1} \leq \frac{\pi}{2}(2x_1)^{-1} = \frac{\pi}{4}x_1^{-1} < \frac{1}{\sqrt{2n_0\pi}} < \frac{1}{\sqrt{n_0}} < \delta$$

以及

$$|f(x_2) - f(x_1)| = \sin\left[\frac{(2n_0 + 1)\pi}{2}\right] - \sin 2n_0\pi = 1 > \varepsilon_0$$

因此, $f(x) = \sin(x^2)$ 在 $[0, +\infty)$ 上不是一致连续



• 一致连续性的性质

- 函数 $f: \mathbb{R} \mapsto \mathbb{R}$ 在 $\mathbb{R}$ 上连续, 且 $\lim_{x \rightarrow -\infty} f(x)$ 和 $\lim_{x \rightarrow +\infty} f(x)$ 存在并有界, 则函数 f 一致连续
- 非有界区间上定义的连续的周期函数是一致连续的
- 范例
 - $f(x) = x^2$ 在 $\mathbb{R}$ 不是一致连续函数
 - $f(x) = x$ 在 $[0, 1]$ 是一致连续函数
 - $f(x) = \frac{1}{x}$ 在 $[1, +\infty)$ 是一致连续函数, 在 $(0, +\infty)$ 不是一致连续函数, 在 $(0, 1)$ 不是一致连续函数
 - $f(x) = \sqrt{x}$ 在 $[1, +\infty)$ 是一致连续函数
 - $f(x) = \tan(x)$ 在 $(-\frac{\pi}{2}, \frac{\pi}{2})$ 不是一致连续函数
 - $f(x) = \exp(x)$ 在 $\mathbb{R}$ 不是一致连续函数



函数的连续性

• 利普希茨连续性 (Lipschitz Continuity) 的定义


给定函数 $f: I = [a, b] \mapsto \mathbb{R}$, 对于 $\forall x_1, x_2 \in I$ 都存在常数 $L \geq 0$, 使

$$|f(x_1) - f(x_2)| \leq L|x_1 - x_2|$$

则称函数 $f(x)$ 在区间 I 内满足利普希茨条件, 也称函数利普希茨连续, 满足不等式的**最小常数 L** 被称为函数 f 的利普希茨常数

• 利普希茨连续性的性质

给定函数 $f: I = [a, b] \mapsto \mathbb{R}$, 对于 $\forall x_1, x_2 \in I$ 都存在常数 L , 使得在任意点 x_0 处, 曲线均夹在直线 $y - f(x_0) = L(x - x_0)$ 和 $y - f(x_0) = -L(x - x_0)$ 之间, 即存在一个双圆锥(白色)其顶点可沿着曲线平移, 使得**曲线总是完全在这两个圆锥外**





• 利普希茨连续性的性质

- 利普希茨连续要求函数图像在曲线上任意两点连线的斜率一致有界，即任意两点的斜率小于同一个常数
 - 从局部看：我们可以取两个充分接近的点，如果这个时候斜率的极限存在的话，这个斜率的极限就是这个点的导数
 - ✓ 可导函数是利普希茨连续，则函数导数有界
 - ✓ 如果函数的导数存在且有界，则函数利普希茨连续
 - 从整体看：利普希茨连续要求函数在无限的区间上不能有超过线性的增长，因此
 - ✓ $f(x) = x^2$ ，在无限区间 $(-\infty, \infty)$ 上不是利普希茨连续的
 - ✓ $f(x) = e^x$ ，在无限区间 $(-\infty, \infty)$ 上不是利普希茨连续的
- 函数 $f(x)$ 利普希茨连续意味着函数上下有界，即

$$f(x_1) - L|x - x_1| \leq f(x) \leq f(x_1) + L|x - x_1|$$




• 利普希茨连续性的几何意义

在任意两点 $(x_1, f(x_1))$ 和 $(x_2, f(x_2))$ 处函数割线斜率的绝对值

$$\tan \alpha = \left| \frac{f(x_2) - f(x_1)}{x_2 - x_1} \right|$$

均不大于 L



- 利普希茨连续性要求函数在区间上不能有**超过线性**的变化速度，对于确保机器学习算法的稳定性有重要的作用



• 利普希茨连续性的几何意义

■ 范例

➤ $\{f: [-3, 7] \mapsto \mathbb{R} \mid f(x) = x^2\}$

在 $[-3, 7]$ 上是利普希茨连续函数，且利普希茨常数为 $L = 14$

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = x^2\}$

在 $\mathbb{R}$ 上不是利普希茨连续函数，因为 $\lim_{x \rightarrow \pm\infty} f'(x) = \pm\infty$

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = \sqrt{x^2 + 5}\}$

在 $\mathbb{R}$ 上是利普希茨连续函数，且利普希茨常数为 $L = 1$

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = x\}$

在 $\mathbb{R}$ 上是利普希茨连续函数，且利普希茨常数为 $L = 1$

➤ $\{f: [1, +\infty) \mapsto \mathbb{R} \mid f(x) = \sqrt{x}\}$ $\frac{1}{2\sqrt{x}}$

在 $[1, +\infty)$ 上是利普希茨连续函数，且利普希茨常数为 $L = 1/2$

但在 $[0, 1]$ 上不是利普希茨连续，因为 $\lim_{x \rightarrow 0} f'(x) = +\infty$



• 利普希茨连续性的几何意义

■ 范例

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = |x|\}$

在 $\mathbb{R}$ 上是利普希茨连续函数，且利普希茨常数为 $L = 1$

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = \sqrt{|x|}\}$

在 $\mathbb{R}$ 上非（局部）利普希茨连续函数，因为 $\lim_{x \rightarrow \infty} \frac{|f(x) - f(0)|}{|x - 0|} = \infty$

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = \exp(x)\}$

在 $\mathbb{R}$ 上不是利普希茨连续函数，因为 $\lim_{x \rightarrow +\infty} f'(x) = +\infty$

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = \tanh(x)\}$

在 $\mathbb{R}$ 上是利普希茨连续函数，且利普希茨常数为 $L = 1$

➤ $\{f: \mathbb{R} \mapsto \mathbb{R} \mid f(x) = \alpha x\}$

在 $\mathbb{R}$ 上是利普希茨连续函数，且利普希茨常数为 $L = \alpha$



函数的连续性


• 利普希茨连续性与深度学习安全

■ 人工神经网络 (Artificial Neural Networks)

给定输入 $\mathbf{x}$ ，神经网络模型可以表征为连续函数

$$\mathbf{y} = f(\mathbf{x})$$

- 一般会选择可导连续函数 $f(\mathbf{x})$ ，但神经网络如果不稳健，通常意味着输入对输出的扰动很大，也就是神经网络表征函数 $f(\mathbf{x})$ 在某些点不够平滑
- 表征函数 $f(\mathbf{x})$ 的函数在定义域上的导数总是小于等于利普希茨常数 L ，且它只由神经网络的参数决定，而与输入 $\mathbf{x}$ 无关
- 对于一个神经网络模型，希望它满足Lipchitz连续性，并且Lipchitz常数 L 的值越小，所获得的神经网络模型越**稳健**





• 凸函数的利普希茨连续性

若函数 $f(x)$ 在闭区间 $[a, b]$ 是**凸的**，则任意 $[c, d] \subset [a, b]$ ($a < c < d < b$)，函数 $f(x)$ 在 $[c, d]$ 是Lipschitz连续的，特别是，函数在开区间 (c, d) 内是连续的

■ 证明

对于任意 $c \leq x < y \leq d$ 有

$$\frac{f(c)-f(a)}{c-a} \leq \frac{f(x)-f(a)}{x-a} \leq \frac{f(y)-f(x)}{y-x} \Rightarrow \left(\frac{f(c)-f(a)}{c-a}\right)(y-x) \leq f(y) - f(x)$$

$$\frac{f(y)-f(x)}{y-x} \leq \frac{f(d)-f(x)}{d-y} \leq \frac{f(b)-f(d)}{b-d} \Rightarrow f(y) - f(x) \leq \left(\frac{f(b)-f(d)}{b-d}\right)(y-x)$$

所以

$$|f(y) - f(x)| \leq L|y - x|$$

$$\text{其中 } L = \max\left\{\left|\frac{f(c)-f(a)}{c-a}\right|, \left|\frac{f(b)-f(d)}{b-d}\right|\right\}$$



• 一致连续性的判别方法


- 定义法
- 函数在闭区间上的连续
- 函数在开区间上的连续+端点极限存在且有限
- 分解成多个一致连续函数的四则运算组合
- 非有界区间上定义的连续周期函数
- 证明利普希茨连续

• Lipschitz连续性的判别方法

- 定义法
- 可导函数，导数有界
- 利普希兹常数 L 取导函数的上确界
- 不可导函数，局部利普希茨连续是否成立
- 更大的区间内的凸性



函数的连续性






函数的阶估计

• 无穷小量 (Infinitesimal Number) 的定义

如果函数 $f(x)$ 在点 x_0 的某个去心邻域内有定义且 $\lim_{x \rightarrow x_0} f(x) = 0$, 则称函数 $f(x)$ 是 $x \rightarrow x_0$ 时的**无穷小量**, 可记作 $f(x) = o(1)$

• 无穷小量的分类

如果函数 $f(x)$ 和 $g(x)$ 都是 $x \rightarrow x_0$ 的无穷小量, 那么



① $f(x)$ 是 $g(x)$ 的**高阶无穷小** (higher-order infinitesimal)

若 $\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = 0$, 记作 $f(x) = o(g(x))$, 例如 $\lim_{x \rightarrow 0} \frac{x^2}{x} = 0$

② $f(x)$ 是 $g(x)$ 的**低阶无穷小** (lower-order infinitesimal)

若 $\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = \infty$, 例如 $\lim_{x \rightarrow 0} \frac{x}{x^2} = \infty$

③ $f(x)$ 是 $g(x)$ 的**同阶无穷小**, 若 $\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = c \neq 0$; 如 $\lim_{x \rightarrow 0} \frac{\sin x}{x} = 1$; 若 $c = 1$ **等价无穷小** (equivalent infinitesimal), 记作 $f(x) \sim g(x)$



函数的无穷小量

• 无穷小量性质

③ 等价无穷小范例

当 $x \rightarrow 0$ 时,

$$a^x - 1 \sim x \ln a$$

$$\arcsin(a)x \sim \sin(a)x \sim (a)x$$

$$\arctan(a)x \sim \tan(a)x \sim (a)x$$

$$\ln(1+x) \sim x$$

$$\sqrt{1+x} - \sqrt{1-x} \sim x$$

$$(1+ax)^b - 1 \sim abx$$

$$\sqrt[b]{1+ax} - 1 \sim \frac{a}{b}x$$

$$1 - \cos x \sim \frac{x^2}{2}$$

$$x - \ln(1+x) \sim \frac{x^2}{2}$$

$$\tan x - \sin x \sim \frac{x^3}{2}$$

$$\tan x - x \sim \frac{x^3}{3}$$

$$x - \arctan x \sim \frac{x^3}{3}$$

$$x - \sin x \sim \frac{x^3}{6}$$

$$\arcsin x - x \sim \frac{x^3}{6}$$



函数的无穷小量

• 等价替换

若 $x \rightarrow x_0$ 时, $f(x)$ 是 $g(x)$ 的等阶无穷小或无穷大, 即 $f(x) \sim g(x)$, 则

$$\lim_{x \rightarrow x_0} h(x)f(x) = A \quad \longleftrightarrow \quad \lim_{x \rightarrow x_0} h(x)g(x) = A$$

$$\lim_{x \rightarrow x_0} \frac{h(x)}{f(x)} = A \quad \longleftrightarrow \quad \lim_{x \rightarrow x_0} \frac{h(x)}{g(x)} = A$$

➤ 在乘除运算中, 等价的两个无穷小可以互相替换而不影响最后结果

➤ 例如, 求极限

$$\lim_{x \rightarrow 0} \frac{\sqrt{1+x} - \sqrt[3]{1+x}}{\ln(1+2x)}$$

$$\frac{\frac{1}{6}}{\frac{2}{2x+1}} = \frac{2x+1}{12}$$

解:

$$(1 + \frac{1}{2}x) - (1 + \frac{1}{3}x) = \frac{1}{6}x = \frac{1}{12}$$



函数的无穷小量

• 等价替换

若 $x \rightarrow x_0$ 时, $f(x)$ 是 $g(x)$ 的等阶无穷小或无穷大, 即 $f(x) \sim g(x)$, 则

$$\lim_{x \rightarrow x_0} h(x)f(x) = A \quad \longleftrightarrow \quad \lim_{x \rightarrow x_0} h(x)g(x) = A$$

$$\lim_{x \rightarrow x_0} \frac{h(x)}{f(x)} = A \quad \longleftrightarrow \quad \lim_{x \rightarrow x_0} \frac{h(x)}{g(x)} = A$$

➤ 在乘除运算中, 等价的两个无穷小可以互相替换而不影响最后结果

➤ 例如, 求极限

$$\lim_{x \rightarrow 0} \frac{\sqrt{1+x} - \sqrt[3]{1+x}}{\ln(1+2x)}$$

解: 因为当 $x \rightarrow 0$, $\ln(1+2x) \sim 2x$ 成立, 所以得到

$$\frac{\sqrt{1+x} - \sqrt[3]{1+x}}{\ln(1+2x)} \sim \frac{\sqrt{1+x} - \sqrt[3]{1+x}}{2x} = \frac{(\sqrt{1+x} - 1) - (\sqrt[3]{1+x} - 1)}{2x}$$



• 等价替换

接上解：根据平方差公式得到

$$\frac{(1+x)^{\frac{1}{2}} - 1}{x} = \frac{(1+x) - 1}{x[(1+x)^{\frac{1}{2}} + 1]} = \frac{1}{(1+x)^{\frac{1}{2}} + 1} \sim \frac{1}{2}$$

当 $x \rightarrow 0$ 时，同样利用立方差公式得到

$$\frac{\sqrt[3]{1+x} - 1}{x} = \frac{1}{(1+x)^{\frac{2}{3}} + (1+x)^{\frac{1}{3}} + 1} \sim \frac{1}{3}$$

当 $x \rightarrow 0$ 时，因此有



$$(1+x)^{\frac{1}{2}} - 1 \sim \frac{x}{2}, \quad (1+x)^{\frac{1}{3}} - 1 \sim \frac{x}{3}$$

最终可求

$$\lim_{x \rightarrow 0} \frac{\sqrt{1+x} - \sqrt[3]{1+x}}{\ln(1+2x)} = \frac{\frac{1}{2} - \frac{1}{3}}{2} = \frac{1}{12}$$

1-4

导数与微分





• 函数导数 (Derivative of Functions) 的定义

设函数 $y = f(x)$ 在点 x_0 的某个邻域内有定义，给 x_0 一个改变量 Δx ，当 Δx 趋于零时，函数值的变化量与自变量变化量比值的**极值**

$$f'(x)|_{x=x_0} := \lim_{\Delta x \rightarrow 0} \frac{dy}{dx} = \lim_{\Delta x \rightarrow 0} \left[\frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x} \right] = \lim_{x \rightarrow x_0} \left[\frac{f(x) - f(x_0)}{x - x_0} \right]$$

称为函数 $y = f(x)$ 在 x_0 处导数，也可记为 $f'(x_0)$ 或 $\frac{df}{dx}|_{x=x_0}$

■ 单侧导数

设函数 $y = f(x)$ 在区间 $[x_0, x_0 + r)$ 内有定义，函数 $f(x)$ 在 x_0 处的右导数定义为

$$f'_+(x_0) = \lim_{x \rightarrow x_0^+} \left[\frac{f(x) - f(x_0)}{x - x_0} \right]$$

在区间 $(x_0 - r, x_0]$ 内 $f(x)$ 在 x_0 处的左导数

$$f'_-(x_0) = \lim_{x \rightarrow x_0^-} \left[\frac{f(x) - f(x_0)}{x - x_0} \right]$$



函数的导数

• 函数导数的性质

- 函数可导的充要条件是左右导数均存在并相等，必要条件是函数连续
- 导数的几何意义是函数在 $(x_0, f(x_0))$ 处切线的斜率，反映了函数值在该点的变化快慢

- 凸函数并不一定可导，例如 $f(x) = |x|$ ，因为

$$f'_+(0) = 1$$

$\neq$

$$f'_-(0) = -1,$$


- 如果函数 $f(x)$ 在给定区间 I 上处处可导，且其导函数 $f'(x)$ 在给定区间 I 上处处连续，则记作

$$f(x) \in C^1(I)$$

- 如果函数 $f(x)$ 在点 x_0 可导



$|f(x)|$ 在点 x_0 可导，例如 $f(x) = x$





函数的导数

• 函数导数的运算

■ 链式法则 (Chain Rule)

$$f'(x) = h'(g(x)) \cdot g'(x)$$

其中 $f(x) = h(g(x))$

■ 反函数的导数

$$(f^{-1})'(y_0) = 1/f'(f^{-1}(y_0)), f(x_0) = y_0$$

• 差分公式 (Difference Formula)

如果 Δx 的值接近于零, 则 $y = f(x)$ 在点 x 处的导数可近似计算为

$$\text{单侧差分公式 } f'(x) \approx \frac{f(x+\Delta x) - f(x)}{\Delta x}$$

或


$$\text{中心差分公式 } f'(x) \approx \frac{f(x+\Delta x) - f(x-\Delta x)}{2\Delta x}$$



函数的导数

人工智能中的激活函数 (Activation Function)


就是在人工神经网络的神经元上运行的函数，负责将神经元的输入映射到输出端



人工神经元的工作原理

$$y = f(z) = f(\mathbf{w}^T \mathbf{x} + b)$$

活性值 y 等于输入 $\mathbf{x}$ 经加权和与偏置 b 后的净输入 z ，经非线性激活函数 $f(\cdot)$





• 人工智能中的激活函数 (Activation Function)

■ 激活函数（增强网络的表示和学习能力）的性质

➢ 连续可导的非线性函数


激活函数是用来加入非线性因素的，因为线性模型的表达能力不够；一般允许少数点上不可导，可导的激活函数可以直接利用数值优化的方法来学习网络参数

➢ 简单的函数及导函数

有利于提高网络计算效率

➢ 导函数的值域合理

不能太大也不能太小，否则影响训练的效率和稳定性






函数的导数

• 人工智能中的常用激活函数及其导数

■ Sigmoid函数

➢ 也称逻辑激活函数（Logistic 函数）



$$f(x) = \frac{1}{1+e^{-x}} \quad \longrightarrow \quad f'(x) = f(x)(1 - f(x))$$

- 一类 S - 型曲线函数，为两端**饱和**函数
- 用于逻辑回归的激活函数，值域为 (0,1)
- 挤压效果：当输入值在 0 附近时，Sigmoid 函数近似为线性函数；当输入值靠近两端时，对输入进行抑制

■ 饱和函数

对于函数 $f(x)$ ，若 $x \rightarrow -\infty$ 时，其导数 $f'(x) \rightarrow 0$ ，则称其为**左饱和**；对于函数 $f(x)$ ，若 $x \rightarrow +\infty$ 时，其导数 $f'(x) \rightarrow 0$ ，则称其为**右饱和**；当同时满足左、右饱和时，就称为两端饱和




函数的导数

• 人工智能中的常用激活函数及其导数

■ 双曲正切函数Tanh函数

是双曲正弦函数与双曲余弦函数的比值

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad \Rightarrow \quad f'(x) = 1 - (f(x))^2$$



- tanh函数是Sigmoid函数向下平移和放大后的结果，值域 $(-1,1)$
- 非零中心化的输出会使得后一层的神经元的输入发生偏置偏移 (Bias shift)，从而进一步使得梯度下降的收敛速度变慢
- 输出是零中心化 (Zero-centered)
- tanh函数的导数更陡峭，比 Logistic函数激活函数收敛得更快
- Sigmoid和tanh函数的缺陷，即在 z 很大或很小时，梯度几乎为零，（由于是饱和函数），因此使用梯度下降优化算法更新网络很慢



函数的导数

人工智能中的常用函数及其导数

- 修正线性单位函数 (Rectified Linear Unit, ReLU, 又称整流线性单元)

斜坡函数 (Ramp function, 搭建人工神经网络最常用的激活函数)


$$f(x) = \max(0, x) \quad f'(x) = \begin{cases} 1, & x > 0 \\ 0, & x < 0 \end{cases}$$

在0处函数
导数无定义

- 在神经网络中，斜坡函数作为神经元的激活函数，使得

$$y = w^T x + b \quad y = \max(0, w^T x + b)$$

- 优点1: 由于没有复杂的数学运算，计算开销小；因此，该模型可
- 训练更快，时间复杂度更低，或预测大时，斜率不会平稳或“饱和”，它没有其他激活函数具有的梯度消失问题（如 Sigmoid或tanh）





• 人工智能中的常用函数及其导数

■ 修正线性单位函数 (Rectified Linear Unit, ReLU, 又称整流线性单元)

➢ 斜坡函数 (Ramp function, 搭建人工神经网络最常用的激活函数)

- 优点2: 特别是左饱和函数, 且在 $x > 0$ 时导数为1, 缓解导数消失问题, 加速梯度下降的收敛速度
- 优点3: 可以被稀疏地激活, 神经元完成加、乘和比较的操作, 产生稀疏的神经网络; 由于所有负输入的ReLU均为零, 因此任何给定的单元都可能根本无法激活
- 缺点1: 非零中心化, 易引入偏置偏移, 影响梯度下降速度
- 缺点2: 神经元坏死, 训练期间, 如果ReLU神经元卡在负侧并且始终输出0, 则它是“死”的, 被称为“**死亡ReLU问题**”

* 只要不是所有数据都为负, 仍可从ReLU中获得一个斜率; 当学习率太高或负偏大时, 可能会出现坏死的问题; 较低的学习率通常可以缓解该问题; 或选择leaky ReLU和ELU




函数的导数

• 人工智能中的常用激活函数及其导数

■ 非饱和函数的优点

- 解决梯度消失的问题：以 ReLU 为例，当 x 小于等于 0 时，ReLU 的梯度为 0，但是当 x 大于 0 时，ReLU 的梯度恒为 1，这样即使是 N 层的梯度相乘，也还是 1，即不会产生梯度消失问题
- 加快收敛速度：同样以 ReLU 为例，由于在训练的过程中 ReLU 产生的梯度不会越来越小，因此有利于网络更快地收敛






• 人工智能中的常用函数及其导数

- 修正线性单位函数 (Rectified Linear Unit, ReLU, 又称整流线性单元)
 - 带泄露线性整流函数 (Leaky ReLU)

$$f(x) = \begin{cases} x, & x > 0 \\ \lambda x, & x < 0 \end{cases} \quad \Rightarrow \quad f'(x) = \begin{cases} 1, & x > 0 \\ \lambda, & x < 0 \end{cases}$$

- 在输入值为正时，带泄露线性整流函数和普通斜坡函数保持一致
- 在输入值为负时，保持一个很小的梯度 λ ，非激活时有非零梯度
- 克服死亡ReLU问题：在实践中通常比其他常用激励函数（如逻辑函数）更好的效果，在深度神经网络应用于图像识别等计算机视觉人工智能领域





• 人工智能中的常用函数及其导数

■ 修正线性单位函数 (Rectified Linear Unit, ReLU, 又称整流线性单元)

➤ 优势

□ 仿生物学原理

□ 简化计算过程

□ 更有效的梯度下降与反向传播：避免梯度爆炸和梯度消失问题

■ 梯度不稳定

在深度神经网络中的梯度是不稳定的，在靠近输入层的隐藏层中或会消失或会爆炸

➤ 产生梯度不稳定的原因：前面层上的梯度是来自后面层上梯度的乘积，当存在过多的层时，就会出现梯度不稳定场景，

➤ 梯度爆炸/消失：当神经网络前面隐藏层的学习速率低于后面隐藏层

的学习速率 即随着隐藏层数目的增加 分类准确率反而下降



函数的导数

• 人工智能中的常用函数及其导数

- 梯度消失的原因：1) 隐藏层的层数过多；2) 采用不合适的激活函数（更容易产生梯度消失，但是也有可能产生梯度爆炸）
- 梯度爆炸的原因：1) 隐藏层的层数过多；2) 权重的初始化值过大
- 梯度消失和梯度爆炸问题都是因为网络太深，网络权值更新不稳定造成的，本质上是因为梯度反向传播中的连乘效应。


■ Softplus 函数

$$f(x) = \ln(1 + e^x) \quad \longrightarrow \quad f'(x) = \frac{e^x}{1 + e^x}$$

- 导数是连续的、非零的、无处不在的
- Softplus函数可看是ReLU函数的光滑近似

■ 归一化指数函数（Softmax 函数）

是逻辑函数的一种推广，用于多分类问题






函数的导数

• 人工智能中的常用函数及其导数

■ Exponential Linear Units (ELU) 函数


$$f(x) = \begin{cases} x, & x > 0 \\ \alpha(e^x - 1), & x \leq 0 \end{cases} \rightarrow f'(x) = \begin{cases} 1, & x > 0 \\ f(x) + \alpha, & x < 0 \end{cases}, \quad \alpha > 0$$



■ 绝对值函数

$$f(x) = \begin{cases} x, & x \geq 0 \\ -x, & x < 0 \end{cases} \quad f'(x) = \begin{cases} 1, & x > 0 \\ -1, & x < 0 \end{cases}$$

在0点处函数不可导，左导数为-1，右导数为1




➤ 用于构造机器学习算法训练目标函数中的正则项

■ 符号函数 (sgn)

$$f(x) = \begin{cases} 1, & x > 0 \\ 0, & x = 0 \\ -1, & x < 0 \end{cases}$$

不连续的符号函数在0点处不可导；
符号函数在非零点处的导数均为0



➤ 用于分类器的预测函数，表示二值化的分类结果



函数的导数

人工智能中的常用函数及其导数

名称	函数图形	方程式	导数	区间	Order of continuity
恒等函数		$f(x) = x$	$f'(x) = 1$	$(-\infty, \infty)$	C^∞
单位阶跃函数		$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0 & \text{for } x \neq 0 \\ ? & \text{for } x = 0 \end{cases}$	$\{0, 1\}$	C^{-1}
逻辑函数 (也被称为S函数)		$f(x) = \sigma(x) = \frac{1}{1 + e^{-x}}$ [1][9]	$f'(x) = f(x)(1 - f(x))$	$(0, 1)$	C^∞
双曲正切函数		$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	$f'(x) = 1 - f(x)^2$	$(-1, 1)$	C^∞
反正切函数		$f(x) = \tan^{-1}(x)$	$f'(x) = \frac{1}{x^2 + 1}$	$\left(-\frac{\pi}{2}, \frac{\pi}{2}\right)$	C^∞
Softsign函数 [1][2]		$f(x) = \frac{x}{1 + x }$	$f'(x) = \frac{1}{(1 + x)^2}$	$(-1, 1)$	C^1
反平方根函数 (ISRU) [2]		$f(x) = \frac{x}{\sqrt{1 + \alpha x^2}}$	$f'(x) = \left(\frac{1}{\sqrt{1 + \alpha x^2}} \right)^2$	$\left(-\frac{1}{\sqrt{\alpha}}, \frac{1}{\sqrt{\alpha}}\right)$	C^∞
线性整流函数 (ReLU)		$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$[0, \infty)$	C^0
带泄漏线性整流函数 (Leaky ReLU)		$f(x) = \begin{cases} 0.01x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0.01 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\infty, \infty)$	C^0
参数化线性整流函数 (PReLU) [4]		$f(\alpha, x) = \begin{cases} \alpha x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(\alpha, x) = \begin{cases} \alpha & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\infty, \infty)$	C^0
带随机参数的线性整流函数 (RRReLU) [2]		$f(\alpha, x) = \begin{cases} \alpha x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$ [2][9]	$f'(\alpha, x) = \begin{cases} \alpha & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\infty, \infty)$	C^0



函数的导数

人工智能中的常用函数及其导数

带参数的线性整流函数(PReLU) ^[24]		$f(\alpha, x) = \begin{cases} \alpha x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(\alpha, x) = \begin{cases} \alpha & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\infty, \infty)$	C^0
指数线性函数(ELU) ^[24]		$f(\alpha, x) = \begin{cases} \alpha(e^x - 1) & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(\alpha, x) = \begin{cases} f(\alpha, x) + \alpha & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\alpha, \infty)$	$\begin{cases} C_1 & \text{when } \alpha = 1 \\ C_0 & \text{otherwise} \end{cases}$
扩展指数线性函数(SELU) ^[27]		$f(\alpha, x) = \lambda \begin{cases} \alpha(e^x - 1) & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$ with $\lambda = 1.0507$ and $\alpha = 1.67326$	$f'(\alpha, x) = \lambda \begin{cases} \alpha e^x & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\lambda\alpha, \infty)$	C^0
S型线性整流函数(SReLU) ^[28]		$f_{t_l, \alpha_l, t_r, \alpha_r}(x) = \begin{cases} t_l + \alpha_l(x - t_l) & \text{for } x \leq t_l \\ x & \text{for } t_l < x < t_r \\ t_r + \alpha_r(x - t_r) & \text{for } x \geq t_r \end{cases}$ $t_l, \alpha_l, t_r, \alpha_r$ are parameters.	$f'_{t_l, \alpha_l, t_r, \alpha_r}(x) = \begin{cases} \alpha_l & \text{for } x \leq t_l \\ 1 & \text{for } t_l < x < t_r \\ \alpha_r & \text{for } x \geq t_r \end{cases}$	$(-\infty, \infty)$	C^0
反平方根线性函数(SRLU) ^[29]		$f(x) = \begin{cases} \frac{x}{\sqrt{1+\alpha x^2}} & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} \left(\frac{1}{\sqrt{1+\alpha x^2}}\right)^2 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$\left(-\frac{1}{\sqrt{\alpha}}, \infty\right)$	C^2
自适应分段线性函数(APL) ^[30]		$f(x) = \max(0, x) + \sum_{i=1}^S a_i^+ \max(0, -x + b_i^+)$	$f'(x) = H(x) - \sum_{i=1}^S a_i^+ H(-x + b_i^+)$	$(-\infty, \infty)$	C^0
SoftPlus函数 ^[32]		$f(x) = \ln(1 + e^x)$	$f'(x) = \frac{1}{1 + e^{-x}}$	$(0, \infty)$	C^∞
哥德堡函数		$f(x) = \frac{\sqrt{x^2 + 1} - 1}{2} + x$	$f'(x) = \frac{x}{2\sqrt{x^2 + 1}} + 1$	$(-\infty, \infty)$	C^∞
Sigmoid-weighted linear unit (SiLU) ^[31] (也被称为Swish ^[32])		$f(x) = x \cdot \sigma(x)$	$f'(x) = f(x) + \sigma(x)(1 - f(x))$	$[-0.28, \infty)$	C^∞
SoftExponential函数 ^[33]		$f(\alpha, x) = \begin{cases} x & \text{for } x \leq 0 \\ \frac{x}{e^{\alpha x} + \alpha} & \text{for } x > 0 \end{cases}$	$f'(\alpha, x) = \begin{cases} 1 & \text{for } x \leq 0 \\ \frac{1}{e^{\alpha x} + \alpha} & \text{for } x > 0 \end{cases}$	$(-\infty, \infty)$	C^∞
正弦函数		$f(x) = \sin(x)$	$f'(x) = \cos(x)$	$[-1, 1]$	C^∞
Sinc函数		$f(x) = \begin{cases} 1 & \text{for } x = 0 \\ \frac{\sin(x)}{x} & \text{for } x \neq 0 \end{cases}$	$f'(x) = \begin{cases} 0 & \text{for } x = 0 \\ \frac{\cos(x)}{x} - \frac{\sin(x)}{x^2} & \text{for } x \neq 0 \end{cases}$	$[-.217234, 1]$	C^∞
高斯函数		$f(x) = e^{-x^2}$	$f'(x) = -2xe^{-x^2}$	$(0, 1]$	C^∞




函数的导数

• 人工智能中的激活函数 (Activation Function)

■ 神经网络的应用

➢ 无人驾驶

自动驾驶算法的训练需要大量真实人类驾车的训练数据，人们试图让深度神经网络理解这些数据，并复现人类遇到这些情况时的反应，自动驾驶算法的端到端表示：






函数的导数

• 人工智能中的激活函数 (Activation Function)

■ 神经网络的应用

➢ 生物启发神经网络用于自动驾驶汽车

受线虫等小型动物大脑的启发，仅用使用 75000 个参数、19 个神经元即可控制自动驾驶汽车，而常规深度神经网络方法（如 Inception、ResNet、VGG 等）则需要数百万神经元





• 函数导数的性质

■ 导数与单调性

若函数 $f(x)$ 在区间 $[a, b]$ 内连续，在区间 (a, b) 内可导，那么若在 (a, b) 内 $f'(x) > 0$ ，则在 $[a, b]$ 内单调递增；若在 (a, b) 内 $f'(x) < 0$ ，在 $[a, b]$ 单调递减

■ 导数与凹凸性

若函数 $f(x)$ 在区间 $[a, b]$ 内连续，在区间 (a, b) 内一二阶可导，那么若在 (a, b) 内 $f''(x)(>) \geq 0$ ，函数在 $[a, b]$ 内为(严格)凸函数；若 $f''(x)(<) \leq 0$ ，函数在 $[a, b]$ 内为(严格)凹函数

■ 导数与连续性

若函数 $y = f(x)$ 在点 x_0 处可导，则 $f(x)$ 在 x_0 处一定连续，反之，则不然



• 函数导数的性质

■ 导数与极值

若函数 $f(x)$ 在点 x_0 的处一二阶导数存在，且 $f'(x_0) = 0$ ，即 x_0 为 $f(x)$ 的一个驻点 (Stationary Point) 或临界点 (Critical Point)，

- 若 $f''(x_0) > 0$ ，则 $f(x_0)$ 为极小值 (极小柱点)
- 若 $f''(x_0) < 0$ ，则 $f(x_0)$ 为极大值 (极大驻点)
- 若 $f''(x_0) = 0$ ，则 $f(x_0)$ 极值性不定 (驻点)


□ 范例

函数 $f(x) = x^3$ 在 $x_0 = 0$ 在处，因为
 $f''(0) = 0$

但是

$$f'(0) = 0$$

因此，点 $x_0 = 0$ 是函数 $f(x) = x^3$ 驻点，
但极值性不确定，即驻点不一定是极值点





函数的导数

• 函数导数的性质

□ 范例：函数

$$f(x) = |x|$$


在 $x_0 = 0$ 处有极小值，但 $x_0 = 0$ 并非驻点，因为 f 在 $x_0 = 0$ 处不可导，即极值点不一定是驻点

- 可导函数的极值点必定是它的驻点
- 可导函数的驻点并不一定是它的极值点
- 费马（Fermat）引理

若 x_0 是 f 的极值点（极大值或极小值）
且 f 在 x_0 处可导，则

$$f'(x_0) = 0$$

严格来说，若 x_0 为 $f(x)$ 的极值点，且 $f'(x_0)$ 存在，则 x_0 为 $f(x)$ 的驻点





• 函数导数的性质

■ 光滑函数 (Smooth Function)

函数 $f(x)$ 在区间 $I \subseteq \mathbb{R}$ 上无穷可导的，即存在所有有限阶导数

- 若函数是连续的，则称其为 $C^0(I)$ 函数；
- 若函数存在一阶导函数，且其导函数连续，则称为连续可导，记为 $C^1(I)$ 函数；
- 若一函数存在 n 阶可导，且其 n 阶导函数连续，记为 $C^n(I)$ 函数；
- 光滑函数是对所有 n 都属于 C^n 函数，称其为 $C^\infty(I)$ 函数，例如指数函数是光滑的，因为指数函数的导数是指数函数本身

□ 范例：函数

$$f(x) = \begin{cases} x^4 \sin \frac{1}{x}, & x \neq 0 \\ 0, & x = 0 \end{cases}$$



函数的导数

• 函数导数的性质

■ 光滑函数 (Smooth Function)

□ 范例：计算得到

$$f'(x) = \begin{cases} 4x^3 \sin \frac{1}{x} - x^2 \cos \frac{1}{x}, & x \neq 0 \\ 0, & x = 0 \end{cases}$$

和

$$f''(x) = \begin{cases} 12x^2 \sin \frac{1}{x} - 6x \cos \frac{1}{x} - \sin \frac{1}{x}, & x \neq 0 \\ 0, & x = 0 \end{cases}$$

$f'(x)$ 和 $f''(x)$ 存在，但 $f''(x)$ 不连续，而 $f'''(x)$ 不存在，即 $f(x) \in \mathcal{C}^2(I)$

□ 练习：

$$f(x) = \begin{cases} e^{-\frac{1}{x}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$



泰勒级数

• 泰勒定理 (Taylor's Theorem)

如果在一个包含 x_0 的区间上的函数 $y = f(x)$ 的 $n + 1$ 阶可导, 那么在对于这个区间上的任意 x , 都有

泰勒展开式(Taylor Polynomial)

$f(x) =$

$$f(x_0) + \frac{f'(x_0)}{1!} (x - x_0) + \frac{f''(x_0)}{2!} (x - x_0)^2 + \cdots + \frac{f^{(n)}(x_0)}{n!} (x - x_0)^n + R_n(x)$$


➤ 余项 $R_n(x)$ 是 $(x - x_0)^n$ 的高阶无穷小

$$\lim_{x \rightarrow x_0} \frac{f(x)}{(x - x_0)^n} = 0$$

■ 皮亚诺型 (Peano) 余项

$$R_n(x) = o[(x - x_0)^n]$$

➤ 皮亚诺余项不能具体估算出误差的大小





泰勒公式

• 泰勒定理 (Taylor's Theorem)

- 施勒米尔希-罗什 (Schlomilch-Roche) 余项

$$R_n(x) = \frac{f^{(n+1)}(x_0 + \theta(x - x_0))}{(n)!p} (1 - \theta)^{n+1-p} (x - x_0)^{(n+1)}, \theta \in (0, 1), p \in \mathbb{N}^+$$

$$p = 1$$

- 柯西 (Cauchy) 余项

$$R_n(x) = \frac{f^{(n+1)}(x_0 + \theta(x - x_0))}{n!} (1 - \theta)^n (x - x_0)^{(n+1)}$$

$$p = n + 1$$

- 拉格朗日型 (Lagrange) 余项

$$R_n(x) = \frac{f^{(n+1)}(\delta)}{(n+1)!} (x - x_0)^{(n+1)}, \delta \in (x_0, x)$$

- 积分型余项

$$R_n(x) = \int_{x_0}^x \frac{f^{(n+1)}(t)}{n!} (x - t)^n dt$$



泰勒公式

• 泰勒定理 (Taylor's Theorem)

□ 范例

➤ 指数函数 $f(x) = e^x$ 在 $x_0 = 0$ 在处的泰勒展开, 其中 $\theta \in (0,1)$

$$e^x = 1 + \sum_{1 \leq k \leq n} \frac{x^k}{k!} + \frac{e^{\theta x}}{(n+1)!} x^{n+1}$$

拉格朗日余数

或

$$e^x = 1 + \sum_{1 \leq k \leq n} \frac{x^k}{k!} + \frac{e^{\theta x} (1-\theta)^n}{n!} x^{n+1}$$

柯西余数

➤ 对数函数 $f(x) = \ln(1+x)$, $x > -1$, 在 $x_0 = 0$ 在处的泰勒展开

$$\ln(1+x) = \sum_{1 \leq k \leq n} (-1)^{k-1} \frac{x^k}{k!} + \frac{(-1)^n}{(n+1)(1+\theta x)^{n+1}} x^{n+1}$$

$$\ln(1+x) = \sum_{1 \leq k \leq n} (-1)^{k-1} \frac{x^k}{k!} + \frac{(-1)^n (1-\theta)^n}{(1+\theta x)^{n+1}} x^{n+1}$$



麦克劳林展开

- 麦克劳林公式 (Maclaurin's Formula)

$$f(x) = f(0) + \frac{f'(0)}{1!}x + \frac{f''(0)}{2!}x^2 + \dots + \frac{f^{(n)}(0)}{n!}x^n + R_n(x)$$

- 导数表示下一个点的走向，阶数表示曲线该怎么逼近，阶乘控制着各个部分起着什么样的作用

- 常用的麦克劳林公式

- 几何级数

$$\frac{1}{1-x} = \sum_{n=0}^{\infty} x^n, \quad \forall x: |x| < 1$$

- 二项式级数

$$(1+x)^\alpha = \sum_{n=0}^{\infty} \binom{\alpha}{n} x^n, \quad \forall x: |x| < 1, \forall \alpha \in \mathbb{C}$$



麦克劳林展开

常用的麦克劳林公式

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!} = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \cdots + \frac{x^n}{n!} + \cdots$$

$$\ln(1-x) = -\sum_{n=1}^{\infty} \frac{x^n}{n} = -x - \frac{x^2}{2} - \frac{x^3}{3} - \cdots - \frac{x^n}{n} - \cdots \quad \forall x \in [-1, 1)$$

$$\ln(1+x) = \sum_{n=1}^{\infty} \frac{(-1)^{n+1}}{n} x^n = x - \frac{x^2}{2} + \frac{x^3}{3} - \cdots + \frac{(-1)^{n+1}}{n} x^n + \cdots \quad \forall x \in (-1, 1]$$

$$\sinh x = \sum_{n=0}^{\infty} \frac{1}{(2n+1)!} x^{2n+1} \quad \forall x$$

$$\cosh x = \sum_{n=0}^{\infty} \frac{1}{(2n)!} x^{2n} \quad \forall x$$

$$\tanh x = \sum_{n=1}^{\infty} \frac{B_{2n} 4^n (4^n - 1)}{(2n)!} x^{2n-1} \quad \forall x : |x| < \frac{\pi}{2}$$

$$\sinh^{-1} x = \sum_{n=0}^{\infty} \frac{(-1)^n (2n)!}{4^n (n!)^2 (2n+1)} x^{2n+1} \quad \forall x : |x| < 1$$

$$\tanh^{-1} x = \sum_{n=0}^{\infty} \frac{1}{2n+1} x^{2n+1} \quad \forall x : |x| < 1$$

$$\arcsin x = \sum_{n=0}^{\infty} \frac{(2n)!}{4^n (n!)^2 (2n+1)} x^{2n+1}$$

$$\arccos x = \frac{\pi}{2} - \arcsin x = \frac{\pi}{2} - \sum_{n=0}^{\infty} \frac{(2n)!}{4^n (n!)^2 (2n+1)} x^{2n+1}$$

$$\arctan x = \sum_{n=0}^{\infty} \frac{(-1)^n}{2n+1} x^{2n+1}$$

$$\sin x = \sum_{n=0}^{\infty} \frac{(-1)^n}{(2n+1)!} x^{2n+1}$$

$$\cos x = \sum_{n=0}^{\infty} \frac{(-1)^n}{(2n)!} x^{2n}$$

$$\tan x = \sum_{n=1}^{\infty} \frac{B_{2n} (-4)^n (1 - 4^n)}{(2n)!} x^{2n-1}$$

$$\sec x = \sum_{n=0}^{\infty} \frac{(-1)^n E_{2n}}{(2n)!} x^{2n}$$



函数的偏导数

• 偏导数 (Partial Derivatives) 的定义

在 $U \in \mathbb{R}^n$ 上的多元函数 $f(x_1, \dots, x_n)$ 在 $(x_1, \dots, x_n)$ 点处对 x_i 的偏导数定义为

$$\frac{\partial f}{\partial x_i}(x_1, \dots, x_n) := \lim_{\Delta x_i \rightarrow 0} \left[\frac{f(x_1, \dots, x_i + \Delta x_i, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{\Delta x_i} \right]$$

也记作 $f'_{x_i}(x_1, \dots, x_n)$


• 偏导数的几何意义

在点 $\mathbf{x} = (c_1, \dots, c_n)$ 处的偏导数代表曲面 $z = f(x_1, \dots, x_n)$ 与 $x_i z$ 和平行的平面 $x_1 = c_1, \dots, x_{i-1} = c_{i-1}, x_i, x_{i+1} = c_{i+1}, \dots, x_n = c_n$

的交线 $z = f(c_1, \dots, c_{i-1}, x_i, c_{i+1}, \dots, c_n)$ 在点 $(c_1, \dots, c_n)$ 处切线的斜率

• 高阶偏导数

$$\frac{\partial^2 f}{\partial x_i \partial x_j}(x_1, \dots, x_n) = \frac{\partial}{\partial x_j} \left(\frac{\partial f}{\partial x_i}(x_1, \dots, x_n) \right)$$





函数的偏导数

- 偏导数的Python程序

求函数 $f(x, y) = e^{xy} \sin(x + y)$ 的偏导数

➢ 使用 Python 包 SymPy 中的函数 diff 求偏导

- Python 代码

```
import sympy
from sympy import *
u,v=symbols('u v')
x,y,z=symbols('x y z')
u=x*y
v=x+y
z=E**u* sin(v)
print(z.diff(x))
print(z.diff(y))
```

- 输出结果

```
y*exp(x*y)*sin(x + y) + exp(x*y)*cos(x + y)
x*exp(x*y)*sin(x + y) + exp(x*y)*cos(x + y)
```



函数的微分

• 函数微分 (Differential of Functions) 的定义

设函数 $y = f(x)$ 在点 x_0 的某个邻域内有定义, 给 x_0 一个改变量 Δx , 如果函数的增量 $\Delta y = f(x_0 + \Delta x) - f(x_0)$ 可表示为

$$\Delta y = A\Delta x + o(\Delta x)$$


其中 A 为不依赖于 Δx 的常数, 那么称函数 f 在点 x_0 是**可微的**

- $A\Delta x$ 称为函数 $y = f(x)$ 在点 x_0 的**微分**, 记为 **dy** , 即 **$dy = A\Delta x$**
- dy 是函数增量 Δy 的**线性主部**, Δx 称为**自变量的微分**, 记作 dx
- 若函数可微, 则


$$dy = f'(x)dx$$

且函数 $f(x)$ 在点 x_0 处可展开为

$$f(x) = f(x_0) + f'(x)(x - x_0) + o(x - x_0)$$



$$\Delta y := f(x) - f(x_0) = f'(x)(x - x_0) + o(x - x_0)$$





函数的微分

• 函数微分性质

- 如果一个函数 $f(x)$ 在定义域中的所有点都存在导数, 则函数 $f(x)$ 为可微函数 (Differential function)
- $y = f(x)$ 在点 x_0 处可微 $\longleftrightarrow$ $f(x)$ 在点 x_0 处可导, 且 $A = f'(x_0)$
- 函数 $y = f(x)$ 在点 x_0 处可微 $\longrightarrow$ 函数在点 x_0 处连续



➢ 函数 $f(x) = |x|$ 连续, 但在点 $x = 0$ 处不可微, 因为

$$\Delta y = f(0 + \Delta x) - f(0) = |\Delta x|$$

如果 $\Delta x > 0$, 则 $\Delta y = \Delta x$; 如果 $\Delta x < 0$, 则 $\Delta y = -\Delta x$; 故不存在这样的常数 A 使得 $\Delta y = A\Delta x + o(\Delta x)$

• 函数微分的几何意义

在 $(x_0, f(x_0))$ 处自变量增加 Δx 时切线函数 $y = f'(x_0)(x - x_0) + f(x_0)$ 的增量是 $f'(x_0)\Delta x$



• 函数的全微分

多元函数 $y = f(x_1, \dots, x_n)$ 在 $(x_1, \dots, x_n)$ 点处的全微分为

$$\begin{aligned} dy &= \frac{\partial f}{\partial x_1} dx_1 + \dots + \frac{\partial f}{\partial x_n} dx_n \\ &= \left[\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right] \cdot d\mathbf{x} \\ &= \langle \nabla f(x_1, \dots, x_n), d\mathbf{x} \rangle \end{aligned}$$

是该函数在该点附近关于其自变量的最佳线性近似

➤ 例如，二元函数 $z = f(x, y)$ 可微，则此函数在点 (x_0, y_0) 的全微分为

$$dz|_{(x_0, y_0)} = f_x(x_0, y_0)dx - f_y(x_0, y_0)dy$$

- 充分条件：函数 $f(x_1, \dots, x_n)$ 在点 $(x_1, \dots, x_n)$ 的某邻域内的各个偏导数存在且偏导函数在该点都连续，则此函数在该点可微
- 必要条件：若多元函数在某点可微，则此函数在该点必连续




微分中值定理

- 罗尔中值定理 (Rolle Mean Value Theorem)
若函数 $f(x)$ 在 $[a, b]$ 内连续, 在 (a, b) 内可导, 且在区间的两个端点处的值相等, 即 $f(a) = f(b)$, 则在 $[a, b]$ 内至少存在一点 ξ , 使得


$$f'(\xi) = 0$$

- 几何意义: 对于区间 $[a, b]$ 两个端点处的函数值相等的函数, 在区间内至少存在一点的导数值为0, 该点处的切线与x轴水平



- 拉格朗日中值定理 (Lagrange Mean-Value)
若函数 $f(x)$ 在 $[a, b]$ 内连续, 在 (a, b) 内可导, 则至少存在 $\xi \in (a, b)$, 使得


$$f'(\xi) = \frac{f(b) - f(a)}{b - a}$$






微分中值定理

- 拉格朗日中值定理 (Lagrange Mean-Value)
 - 几何意义：对于区间 (a, b) 内至少存在一点 $(\xi, f(\xi))$ ，该点处的切线与 a 和 b 之间的割线平行，即斜率相等
- 柯西中值定理 (Cauchy Mean Value Theorem)
 - 若 $f(x)$ 和 $g(x)$ 在 $[a, b]$ 连续，在 (a, b) 可导，且 $\forall x \in (a, b)$ 有 $g'(x) \neq 0$ ，则存在 $\xi \in (a, b)$ ，使得
$$\frac{f'(\xi)}{g'(\xi)} = \frac{f(b) - f(a)}{g(b) - g(a)}$$
 - 几何意义：令 $u = f(x), v = g(x)$ ，表示为参数方程，而等式右则表示连接参数曲线两端点的弦的斜率，左侧表示曲线上某点处切线的斜率，则定理表示的曲线上至少有一点，在这一点处的切线平行于连接两个端点的弦



$$g(x) = x$$





函数的梯度与方向导数

• 函数梯度 (Gradient)

多元函数 $f(x_1, \dots, x_n)$ 的梯度是对所有自变量的偏导数形成的向量

梯度算子

$$\nabla f(x_1, \dots, x_n) := \text{grad } f(x_1, \dots, x_n) = \left[\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right]^T$$

- 可导函数在极值点处的梯度为零向量 $\mathbf{0}$ ，梯度为 $\mathbf{0}$ 的点称为多元函数的驻点
- 梯度是导数对多元函数的推广，它是多元函数对各个自变量求偏导数形成的向量，其作用相当于一元函数的导数

• 函数方向导数 (Directional Derivative)


函数 $f(x_1, \dots, x_n)$ 在点 $\mathbf{x}$ 处沿方向 $\mathbf{v}$ 的方向导数

单位向量

向量内积

$$\frac{df_v}{dt} = \mathbf{v} \cdot \nabla f = \lim_{t \rightarrow 0} \left[\frac{f(\mathbf{x} + t\mathbf{v}) - f(\mathbf{x})}{t} \right]$$

- 函数在某点的梯度的方向与函数取得最大方向导数的方向一致，而它的模为方向导数的最大值



$$\text{grad} [-(\cos^2 x + \cos^2 y)^2]$$



综合案例—梯度下降法

• 迭代法 (Iterative Method)

迭代法也称辗转法，是一种不断用变量的旧值递推新值的过程

➤ 迭代算法是用计算机解决问题的一种基本方法，它利用计算机运算速度快、适合做重复性操作的特点，让计算机对一组指令(或一定步骤)进行重复执行，在每次执行这组指令(或这些步骤)时，都从变量的原值推出它的一个新值

➤ 迭代法又分为精确迭代和近似迭代

■ 迭代法的用途：求函数极值点

➤ 驻点法： $f'(x) = 0$ 或 $\text{grad } f(x_1, \dots, x_2) = 0$

$$f(x_1, x_2) = x_1^3 - 2x_2^2 + e^{x_1x_2} - x_2 + 10y_2^2 + 100\sin(x_1x_2)$$

➤ 迭代法（近似求解法）

$$[x_1, \dots, x_n]^T(k+1) = h([x_1, \dots, x_n]^T(k))$$

计算数学中，还可应用于（非）线性方程组的解、矩阵的特征值等



综合案例—梯度下降法

• 梯度下降法 (Gradient Descent Method) 的原理

也称最陡下降法，通过**迭代搜索**的方式寻找**可微函数 $f(x)$ 的局部极小值**，即必须向函数当前点对应梯度 $\nabla f(x)$ (或者是近似梯度) 的反方向以**规定步长 α** 距离点进行迭代搜索

- 已知**可微**函数 $f(x)$ 的初始值 x_0 和迭代步长 α ，假设在 x_0 的梯度为 $\nabla f(x_0)$ ，那么下一个点的坐标为

$$x_1 = x_0 - \alpha \cdot \nabla f(x_0)$$


然后再求点 x_1 的梯度 $\nabla f(x_1)$ ，

$$x_2 = x_1 - \alpha \cdot \nabla f(x_1)$$

⋮

$$x_{n+1} = x_n - \alpha \cdot \nabla f(x_n)$$

反复迭代，直到的绝对差 $|f(x_n) - f(x_{n-1})| < \varepsilon$ (极小)，迭代结束，此时 $f(x_n)$ 的即为极小值





综合案例—梯度下降法

• 梯度下降法 (Gradient Descent Method) 的原理


- 步长 (learning rate) : 步长决定了在梯度下降迭代的过程中, 每一步沿梯度负方向前进的长度; 在机器学习中, α 为学习率
 - α 过小, 收敛速度较慢;
 - α 过大, 迭代过程会出现震荡或不收敛
- 初值问题: 初始值选择不同, 获得的函数最小值也有可能不同
 - 若 (损失) 函数 $f(x)$ 为凸函数, 能够保证收敛到全局最小值
 - 若函数 $f(x)$ 为非凸函数, 只能够收敛到局部最小值
- 范例: 假设可微函数 $f(x) = x^2$, $x(0) = 1$, $\alpha = 0.4$

$$x(1) = x(0) - 0.4 * f'(x(0)) = 0.2$$

$$x(2) = x(1) - 0.4 * f'(x(1)) = 0.04$$

$$x(3) = x(2) - 0.4 * f'(x(2)) = 0.008$$

$$x(4) = x(3) - 0.4 * f'(x(3)) = 0.00016$$





综合案例—梯度下降法

• 梯度下降法 (Gradient Descent Method) 的原理

- 范例：假设可微函数

$$f(\mathbf{x}) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$$

给定初值 $\mathbf{x}(0) = [0,0]^T$ ，步长 $\alpha = 0.1$ ，函数梯度为

$$\nabla f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2} \right]^T = [1 - 4x_1 + 2x_2, -1 + 2x_1 + 2x_2]^T$$



$$\mathbf{x}(1) = \mathbf{x}(0) - 0.1 * \nabla f(\mathbf{x}(0)) = [-0.1, 0.1]^T$$

$$\mathbf{x}(2) = \mathbf{x}(1) - 0.1 * \nabla f(\mathbf{x}(1)) = [-0.18, 0.2]^T$$


$$\mathbf{x}(3) = \mathbf{x}(2) - 0.1 * \nabla f(\mathbf{x}(2)) = [-0.248, 0.296]^T$$

$$\mathbf{x}(4) = \mathbf{x}(3) - 0.1 * \nabla f(\mathbf{x}(3)) = [-0.308, 0.3864]^T$$

$$\mathbf{x}(5) = \mathbf{x}(4) - 0.1 * \nabla f(\mathbf{x}(4)) = [-0.36208, 0.47072]^T$$

$$\mathbf{x}(6) = \mathbf{x}(5) - 0.1 * \nabla f(\mathbf{x}(5)) = [-0.411392, 0.548992]^T$$

⋮





综合案例—梯度下降法

• 梯度下降法的案例

应用Python编程实现梯度下降法求解函数的最小值，并使用Matplotlib、mpl_toolkits库画出函数的图形

$$\min f(x) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$$

给定初值 $(x_1(0), x_2(0)) = (0,0)$

- matplotlib.pyplot 函数使图像 figure 做出改变
- mpl_toolkits.mplot3d 是三维绘图工具包

• Python 代码

```
import matplotlib.pyplot as plt
import numpy as np
from mpl_toolkits.mplot3d import Axes3D
def Fun(x, y):
    return x - y + 2 * x **2 + 2 * x * y + y **2
def PxFun(x, y):
    return 1 + 4 * x + 2 * y
def PyFun(x, y):
    return -1 + 2 * x + 2 * y
```



综合案例—梯度下降法

• Python 代码


```
fig = plt.figure()
ax = Axes3D(fig)
X, Y = np.mgrid[-2:2:40j, -
2:2:40j]
Z = Fun(X, Y)
ax.plot_surface
(X, Y, Z, rstride=1, cstride=1,
cmap='rainbow')
ax.set_xlabel('x')
ax.set_ylabel('y')
ax.set_zlabel('z')
step = 0.0008
x = 0
y = 0
tag_x = [x]
tag_y = [y]
tag_z = [Fun(x, y)]
new_x = x
new_y = y
Over = False
```

```
while Over == False:
    new_x -= step * PxFun(x, y)
    new_y -= step * PyFun(x, y)
    if np.abs(Fun(x, y) - Fun(new_x,
new_y)) < 7e-9:
        Over = True
    x = new_x
    y = new_y
    tag_x.append(x)
    tag_y.append(y)
    tag_z.append(Fun(x, y))
ax.plot(tag_x, tag_y, tag_z, 'r')
plt.title('(x,y)~(' + str(x) +
', ' + str(y) + ')')
plt.show()
```





综合案例—梯度下降法

- 输出结果



函数的图形视角一



函数的图形视角二

解为 $x \approx -0.9979$, $y \approx 1.4967$



• 常微分方程 (Ordinary Differential Equation, ODE) 基本概念

含有自变量、未知一元函数 $y = y(x)$ 以及函数各阶导数的方程

$$f(x, y^{(n)}, \dots, y', y) = 0, \text{ 记 } \frac{dy}{dx} = y'$$

称为**常微分函数**，它的解为一元函数，微分方程的**阶数** (Order) 为 n

➤ 范例

$$\frac{dy}{dx} + xy = 0, \quad y''' + yy' = x$$

- 如果微分方程是未知函数 $y = y(x)$ 以及各阶导数的一次方程，则称为线性微分方程

$$a_n(x)y^{(n)} + a_{(n-1)}(x)y^{(n-1)} + \dots + a_0(x)y = g(x)$$

其中 $a_n(x) \neq 0$ ；否则为**非线性微分方程**

- 若系数 $a_1(x), \dots, a_n(x)$ 都是常数，则称为**常系数线性微分方程**
- 若 $g(x) = 0$ ，则称为**齐次**（线性、非线性）微分方程



• 常微分方程 (Ordinary Differential Equation, ODE) 基本概念

- 若微分方程含有未知多元函数 $y = h(x_1, x_2, \dots, x_n)$ 及其若干阶偏导数的微分方程，即

$$f\left(y, x_1, \dots, x_n, \frac{\partial y}{\partial x_1}, \dots, \frac{\partial y}{\partial x_n}, \dots, \frac{\partial^m y}{\partial x_1^m}, \dots, \frac{\partial^m y}{\partial x_n^m}\right) = 0$$

称为偏微分方程 (partial differential equation, PDE)，其中最高阶偏导数的阶称为偏微分方程的阶

• 微分方程的解

- 若 n 阶微分方程的解

$$y = \varphi(x, c_1, \dots, c_n)$$

- 包含 n 个独立的任意常数 $c_1, \dots, c_n$ ，则称该解为方程的通解 (general solution)
- 如果方程的解 $y = \varphi(x)$ 不含任意常数，则称特解 (particle solution)



• 常微分方程的初值问题

微分方程的解通常不唯一，加限定条件可保证解的唯一性，可指定函数在某一个点或某些点处的值 $y(x_0) = c_0$ 或其导数在某一点处的值 $y'(x_0) = c_1$

- 柯西-利普希茨定理 (Cauchy-Lipschitz Theorem)：对于一阶非线性微分方程

$$\frac{dy}{dx} = f(x, y), \quad y(x_0) = y_0$$

对于 $y_0 \in \mathbb{R}$ ， $f(x, y)$ 在 $(0, y_0) \in \mathbb{R}^2$ 附近连续，且 $f(x, y)$ 对 y 是利普希茨连续的，即

$$|f(x, y_1) - f(x, y_2)| \leq L|y_1 - y_2|$$

则在 $x = 0$ 附近函数 $y(x)$ 存在唯一的

- 数值方法近似求解：龙格-库塔 (Runge-Kutta) 法和理查森法



• 常微分方程的初值问题

■ 一阶线性微分方程的解

➤ 齐次方程: $\frac{dy}{dx} + ay = 0 \quad \Rightarrow \quad y = Ce^{-ax}$

➤ 非齐次方程: $\frac{dy}{dx} + ay = b(x) \quad \Rightarrow \quad y = e^{-ax} \left(\int e^{ax} b(x) dx + C \right)$

➤ $\frac{dy}{dx} + a(x)y = b(x) \quad \Rightarrow \quad y = e^{-\int a(x) dx} \left(\int e^{\int a(x) dx} b(x) dx + C \right)$

证明: 将方程两边同乘以 $e^{\int a(x) dx}$, 得到

$$y' e^{\int a(x) dx} + a(x) e^{\int a(x) dx} y = b(x) e^{\int a(x) dx}$$

即

$$(e^{\int a(x) dx} y)' = b(x) e^{\int a(x) dx}$$

因此,

$$e^{\int a(x) dx} y = \int b(x) e^{\int a(x) dx} dx + C$$



常微分方程

- Python求解常微分方程

求解微分方程 $y^4 - 2y''' + 5y'' = \sin x$

‣ 使用 Python 包 SymPy 中的 dsolve 求解微分方程的解析解

- Python 代码

```
import sympy
from sympy import *



x = symbols('x')
y = Function('y')
eq = y(x).diff(x,4)-2*y(x).diff(x,3)+5*y(x).diff(x,2)
print(dsolve(eq,y(x)))
```

- 输出结果

Eq(y(x), C1 + C2*x + (C3*sin(2*x) + C4*cos(2*x))*exp(x))

1-5

积分学





函数的不积分

• 函数不定积分 (Indefinite Integral of Function) 的定义

如果定义在区间 I 上的函数 $f(x)$ 存在可导的函数 $F(x)$, 即 $F'(x) = f(x)$, 则 $F(x)$ 是 $f(x)$ 的一个原函数, 那么 $F(x) + C$ 为 $f(x)$ 的全体原函数

$$\int f(x)dx = F(x) + C, \quad C \text{ 为任意常数}$$

其中 $f(x)$ 被称为被积函数, 注意函数连续是可积的充分条件

• 函数不定积分的计算

■ 换元积分法

➤ 凑微分法

$$\int f(u(x))u'(x)dx = \int f(u)du$$

➤ 变量替换法

$$x = u(t) \quad \longrightarrow \quad \int f(x)dx = \int f(u(t))du(t) \quad \longrightarrow \quad t = u^{-1}(x)$$

■ 分部积分法

$$\int f g'(x)dx = f(x)g(x) - \int f'(x)g(x)dx$$




函数的定积分

- **函数定积分 (Integral of Function) 的定义**

函数 $f(x)$ 在区间 $[a, b]$ 上的定积分记为

$$\int_a^b f(x)dx = \lim_{\Delta x \rightarrow 0} \sum_{i=1}^n f(\xi_i) \Delta x_i$$

表示函数在某区间上与横轴围成区域的面积



- **牛顿-莱布尼茨公式 (Newton-Leibniz)**

如果函数 $f(x)$ 在区间 $[a, b]$ 内可积, 则

$$\int_a^b f(x)dx = F(b) - F(a) = F|_a^b$$

一个连续函数在区间上的定积分等于它的任意一个原函数在区间上的增量 (区间两个端点处函数值之差)





函数的定积分

• 牛顿-莱布尼茨公式的几何意义

如果函数 $y = f(x)$ 把区间 $[a, b]$ 分为4份（左图），整体等于部分之和，即 $f(b) - f(a) = \sum \Delta y$ ；继续细分（右图），把区间均分到最细，即间隔为 dx ，对应的函数增量 Δy 也变成了函数的微分 dy ，所以 $f(b) - f(a) = \sum dy$ ；根据微分的无限细分可知 $dy = f'(x)dx$ ，因此

$$f(b) - f(a) = \sum dy = \sum f'(x)dx = \int_a^b f'(x)dx$$

由牛顿-莱布尼茨公式可知， $f(x)$ 为 $f'(x)$ 的原函数



积分中值
定理

$$\int_a^b f(x)dx = f(\xi)(b - a) = F'(\xi)(b - a) = F(b) - F(a)$$

微分中值
定理



• 引理

如果函数 $f(x)$ 在区间 $[a, b]$ 内连续, 函数 $\eta(x)$ 满足端点约束条件 $\eta(a) = \eta(b) = 0$, 如果对任意的 $\eta(x)$, 都有 $\int_a^b f(x)\eta(x)dx = 0$, 那么有 $f(x) \equiv 0$

■ 证明 (反证法)

假设 $f(x)$ 不恒等于 0, 由于 $\eta(x)$ 是满足端点值约束条件的任意函数,

$$\eta(x) = -f(x)(x-a)(x-b)$$

显然此函数满足端点值约束条件, 且在 (a, b) 内有 $-(x-a)(x-b) > 0$

因此, 可得到下列矛盾处

$$\int_a^b f(x)\eta(x)dx = \int_a^b -f(x)f(x)(x-a)(x-b)dx > 0$$



函数的积分

- Python求解函数积分

求函数积分 $y = \int_0^2 e^x \cos x \, dx$

‣ 使用 Python 包 SymPy 中的 integrate 函数求解定积分

- Python 代码

```
import sympy
from sympy import *

x=symbols('x')
fx=E**x*cos(x)
Fx=integrate(fx,(x,0,2))
print(Fx)
print(N(Fx))
```

- 输出结果

```
exp(2)*cos(2)/2 - 1/2 + exp(2)*sin(2)/2
1.32195868839445
```



函数的积分

• Python求解函数多元积分

计算 $\iint_D xy^2 dx dy$, 其中 D 为由 $x + y = 2$ 、 $x = \sqrt{y}$ 、 $y = 2$ 所围成的有界区域

■ 绘制积分区域

- 使用 Python 包 SymPy 中的 solve 函数求解方程组 $x + y = 2$ 、 $x = \sqrt{y}$ (x 为非负数)

```
import sympy
from sympy import *
x, y = symbols('x y')
sol = solve([x+y-2, x-sqrt(y)], [x, y])
print(sol)
```

■ 输出结果 $[(1, 1)]$




函数的积分

- Python求解函数多元积分

- 使用 Python 包 Matplotlib 中的 plot 和 fill_betweenx 函数绘制积分区域

```
import numpy as np
import matplotlib.pyplot as plt
x = np.linspace(1, -2, 100)
y1 = 2-x
y2 = x**2
y3 = 0*x+2
plt.plot(x, y1, c='g')
plt.plot(x, y2, c='r')
plt.plot(x, y3, c='b')
y = np.linspace(1, 2, 100)
x1 = 2-y
x2 = np.sqrt(y)
plt.fill_betweenx(y, x1, x2, x1 <= x2, facecolor='lightgray')
plt.show()
```

■ 输出结果





函数的积分

- Python求解函数多元积分

- 计算

- 使用 Python包SymPy中的integrate函数先对 x 求积分后以 y 求积分

- Python 代码

```
import sympy
from sympy import *
r, theta = symbols('r theta')
x = r*cos(theta)
y = r*sin(theta)
f = simplify(x*x + y*y)
print(f)
```

- 输出结果

r^2



函数的积分

- Python求解函数多元积分

- 计算

- 使用 Python包SymPy中的integrate函数先对 x 求积分后以 y 求积分

- Python 代码

```
import sympy
from sympy import *
r, theta = symbols('r theta')
x = r*cos(theta)
y = r*sin(theta)
f = simplify(x*x + y*y)
print(f)
```

- 输出结果

r^2



数值积分常用Python函数

序号	函数名	描述
1	quad	单积分
2	dblquad	二重积分
3	tplquad	三重积分
4	nquad	n倍多重积分
5	fixed_quad	高斯积分，阶数为n
6	quadrature	高斯正交到容差
7	romberg	Romberg积分
8	trapz	梯型规则
9	cumtrapz	梯型法则累计计算积分
10	simps	辛普森的规则
11	romb	Romberg积分
12	polyint	分析多项式积分（Numpy）
13	poly1d	辅助函数polyint（Numpy）



欢迎大家交流和讨论!

刘昌鑫

E-mail: changxinl@ecust.edu.cn